Machine Learning

Aprendizaje no supervisado

Pablo Hernández Cámara
pablo.hernandez-camara@uv.es

Pedro Ramón Ventura Gómez
pventura@march-am.com

27/28 Marzo 2026

Índice

1. Aprendizaje no supervisado: Fundamentos
2. Reducción de dimensionalidad:
   1. Selección de características
   2. Extracción de características
4. Clustering
5. Métricas

Aprendizaje no supervisado: Fundamentos

Aprendizaje no supervisado: Fundamentos

IA es...

1. Datos $$[\{y_1, X_1\}, \{y_2, X_2\}, \ldots \{y_N, X_N\}] = [\mathbf{y}, \mathbf{X}]$$
2. Modelo $$\hat{y}_i = f(X_i, \theta)$$
3. Objetivo $$D(\hat{\mathbf{y}}, \mathbf{y})$$
4. Aprendizaje $$\min_{\theta} D(\hat{\mathbf{y}}, \mathbf{y})$$

Sensitivity: C2 Internal

Aprendizaje no supervisado: Fundamentos

IA es…

1. Datos $[\{y_1, X_1\}, \{y_2, X_2\}, \ldots \{y_N, X_N\}] = [\mathbf{y}, \mathbf{X}]$
2. Modelo $\hat{y}_i = f(X_i, \theta)$
3. Objetivo $D(\hat{\mathbf{y}}, \mathbf{y})$
4. Aprendizaje $\min_{\theta} D(\hat{\mathbf{y}}, \mathbf{y})$

Sensitivity: C2 Internal

Aprendizaje no supervisado: Fundamentos

Supervisado (X,Y) vs No-supervisado (X)

En supervisado tenemos las etiquetas/clases/predicciones reales que queremos obtener con nuestro modelo.

En no supervisado únicamente tenemos los datos.

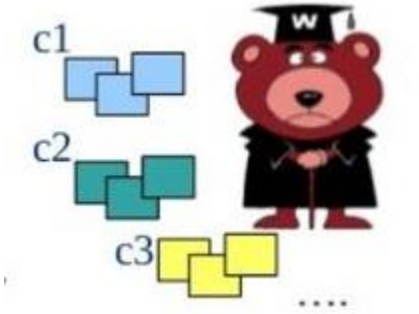

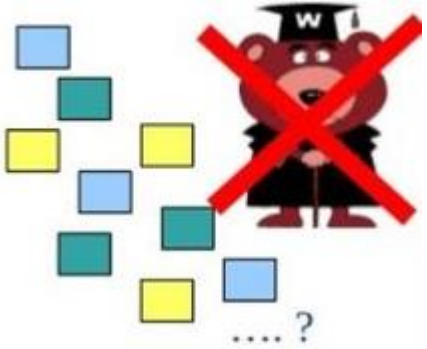

Sensitivity: C2 Internal

Aprendizaje no supervisado: Fundamentos

Tener etiquetas (y) de los datos es caro, requiere mucho tiempo.

Cityscapes dataset

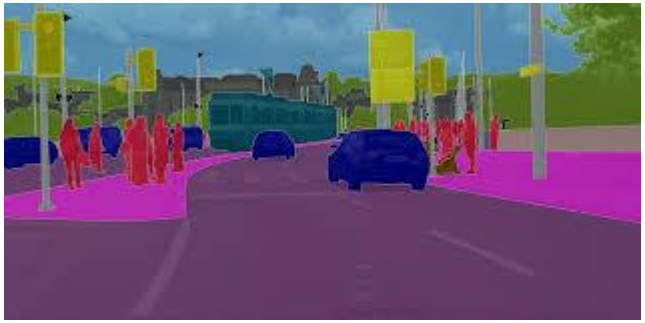

~1.5 hours per image

Sensitivity: C2 Internal

Aprendizaje no supervisado: Fundamentos

Pero tener solo los datos, sin etiquetas, es practicamente gratis.

Label = cat

Solo imágenes, no etiquetas

Sensitivity: C2 Internal

Aprendizaje no supervisado: Fundamentos

UNSUPERVISED LEARNING VS SUPERVISED LEARNING		
Properties	Unsupervised learning	Supervised learning
Definition	Unsupervised learning is the type of machine learning that happens without human supervision. A machine tries to find any patterns in data by itself.	Supervised learning is the type of machine learning that happens under human supervision, meaning people label input data with answer keys showing a machine the desired outputs.
Input data	Unlabeled	Labeled
Use of data	A model is given only input variables (X) and no corresponding output data.	A model is given input variables (X), output variables (Y), and an algorithm to learn the function from input to output.
When to use	You don't know what you're looking for in data.	You know what you're looking for in data.

Sensitivity: C2 Internal

Aprendizaje no supervisado: Fundamentos

Al tener solo datos (X) y no etiquetas (y) los problemas que podemos resolver son distintos. Entre otros:

- Reducción de dimensionalidad
- Problemas de asociación (aglomerativos)
- Generación de nuevos datos (no condicionada)

Sensitivity: C2 Internal

Aprendizaje no supervisado: Fundamentos

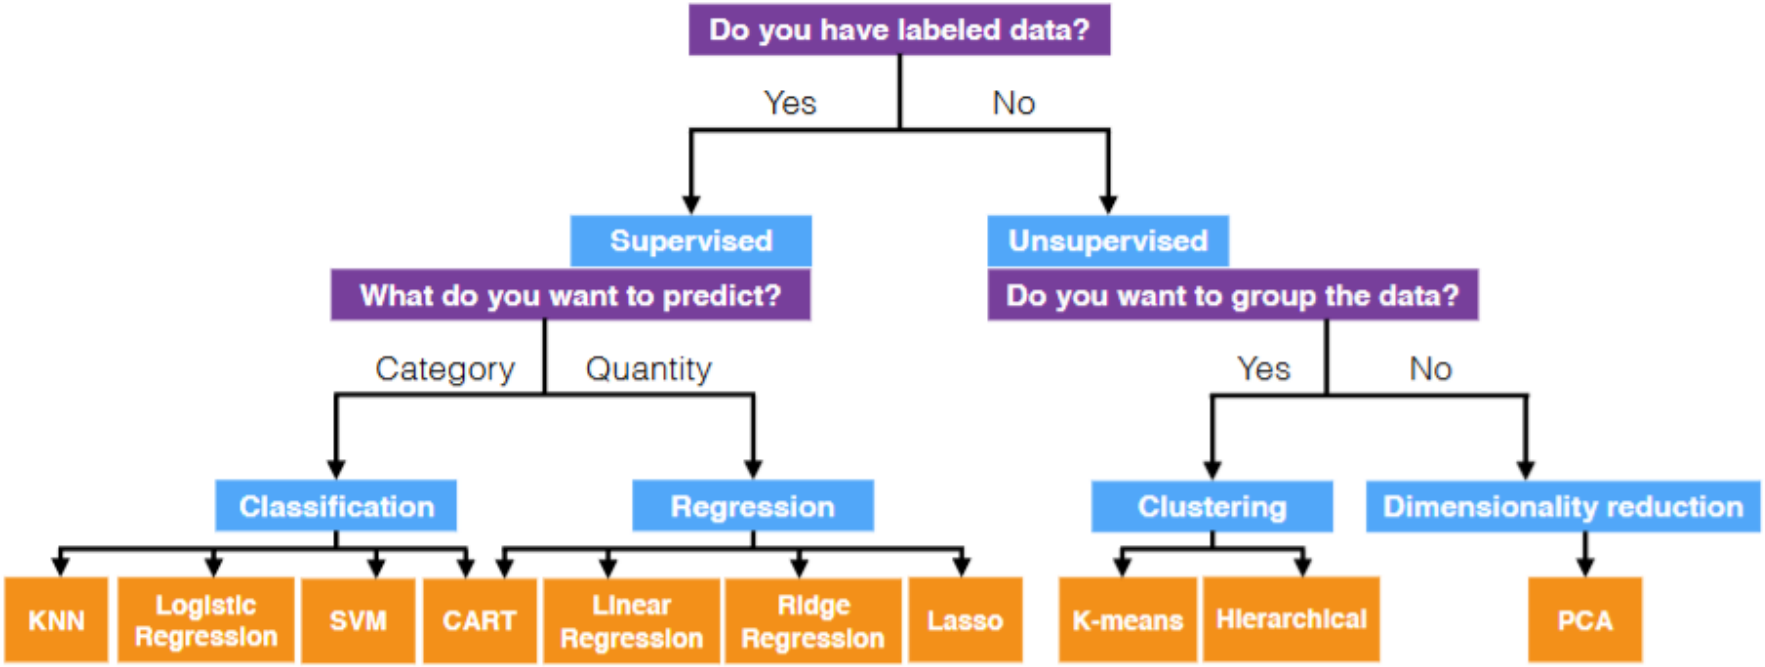

Sensitivity: C2 Internal

Reducción de la dimensionalidad

Reducción de la dimensionalidad

¿Por que es importante para la IA?

La maldición de la dimensionalidad (Bellman, 1961):

Problema de analisis de datos multivariante conforme las dimensiones aumentan.

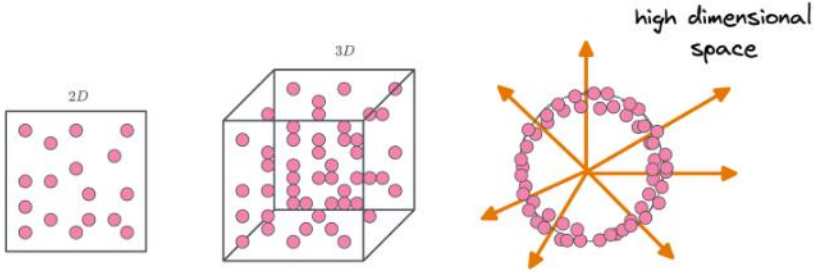

Sensitivity: C2 Internal

Reducción de la dimensionalidad

Ejemplo: Problema de clasificación (3 clases)

Solución fácil: 1) Dividir la variable en intervalos uniformes.

2) Calcular clase más común en cada intervalo.

3) Para nuevo dato: encontrar su intervalo, predecir su clase.

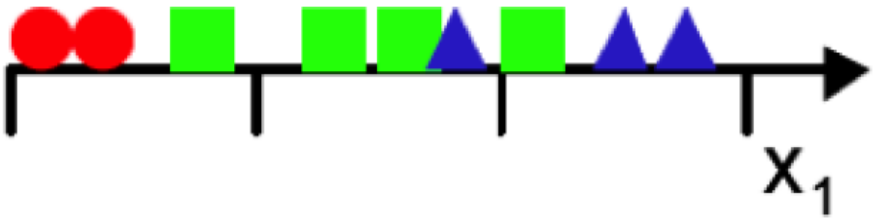

Sensitivity: C2 Internal

Reducción de la dimensionalidad

Ejemplo: Problema de clasificación (3 clases)

Como hay mucho solapamiento pensamos en añadir una 2ª variable.

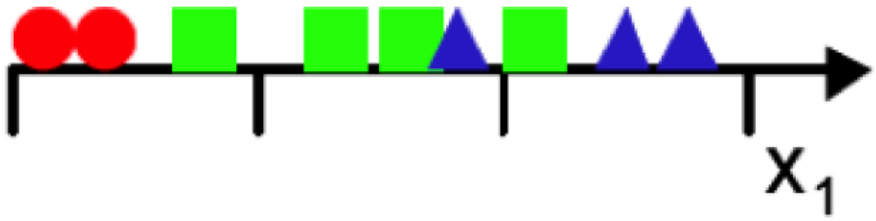

Sensitivity: C2 Internal

Reducción de la dimensionalidad

Ejemplo: Problema de clasificación (3 clases)

Al pasar a 2 variables, el número de bins aumenta de 3 (1D) a 9 (2D).

Para mantener densidad necesitamos de 9 (1D) a 27 datos (2D).

Si mantenemos los datos, el espacio está muy vacio.

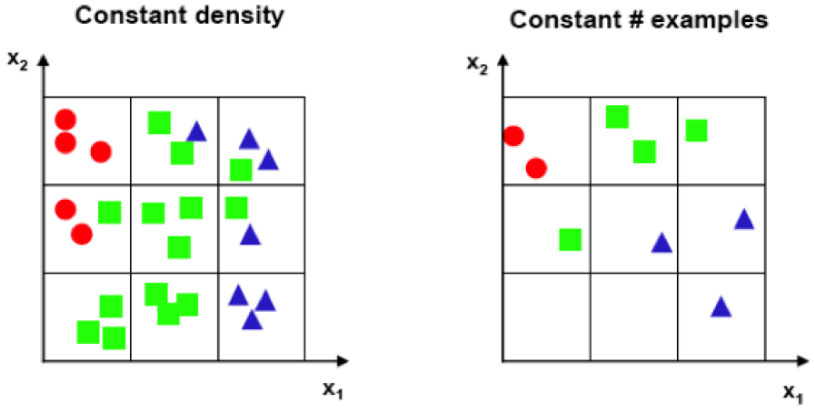

Sensitivity: C2 Internal

Reducción de la dimensionalidad

Ejemplo: Problema de clasificación (3 clases)

Si pasamos a 3D es todavia peor: Ahora hay 27 bins (3^3).

Para mantener densidad necesitamos ahora 81 datos.

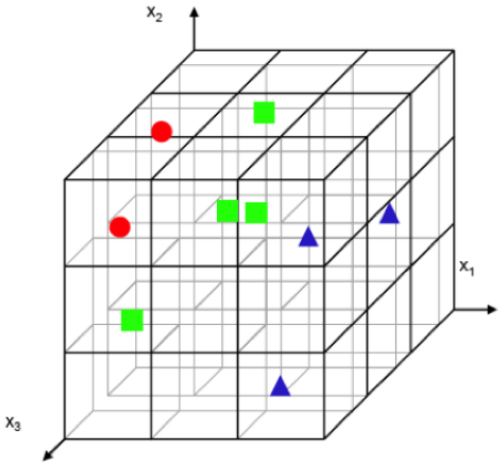

Sensitivity: C2 Internal

Reducción de la dimensionalidad

Maldición de la dimensionalidad

Aumentar las dimensiones (variables) no siempre es bueno si no aumentan los datos también.

Para una cantidad de datos fija, si aumentamos mucho las variables obtendremos peores resultados, hay un número óptimo.

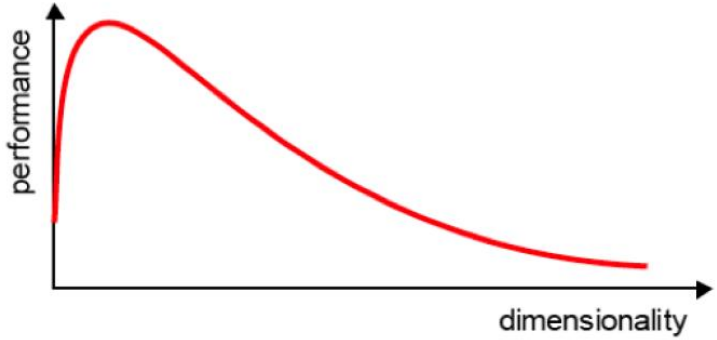

Sensitivity: C2 Internal

Reducción de la dimensionalidad

Maldición de la dimensionalidad

¿Ópciones?

Sensitivity: C2 Internal

Reducción de la dimensionalidad

Maldición de la dimensionalidad

¿Ópciones?

1) Incorporar conocimiento previo.

Sensitivity: C2 Internal

Reducción de la dimensionalidad

Maldición de la dimensionalidad

¿Ópciones?

2) Reducir la dimensionalidad de los datos (reducir variables).

Sensitivity: C2 Internal

Reducción de la dimensionalidad

Maldición de la dimensionalidad

¿Ópciones?

2) Reducir la dimensionalidad de los datos (reducir variables).

En general, la información perdida al reducir variables se compensa al trabajar en un conjunto de menor dimensionalidad y se obtienen mejores resultados.

Sensitivity: C2 Internal

Reducción de la dimensionalidad

Maldición de la dimensionalidad

¿Ópciones?

2) Reducir la dimensionalidad de los datos (reducir variables).

Además, se obtienen modelos más interpretables, que entrenan más rápido y se reduce el almacenamiento requerido.

Sensitivity: C2 Internal

Reducción de la dimensionalidad

¿Cómo reducimos la dimensionalidad?

Pasar de N variables a M variables (M < N)

Sensitivity: C2 Internal

Reducción de la dimensionalidad

¿Cómo reducimos la dimensionalidad? De N a M variables (M < N)

1) Feature selection (Selección de características): Elegir M variables de entre las N variables originales.

2) Feature extraction (Extracción de características): Crear un conjunto de M nuevas variables a partir de las N originales

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} \xrightarrow[\text{feature selection}]{} \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{iM} \end{bmatrix} \qquad \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} \xrightarrow[\text{feature extraction}]{} \begin{bmatrix} x'_1 \\ x'_2 \\ \vdots \\ x'_M \end{bmatrix} = f\left(\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}\right)$$

Sensitivity: C2 Internal

Reducción de la dimensionalidad

¿Cómo reducimos la dimensionalidad? De N a M variables (M < N)

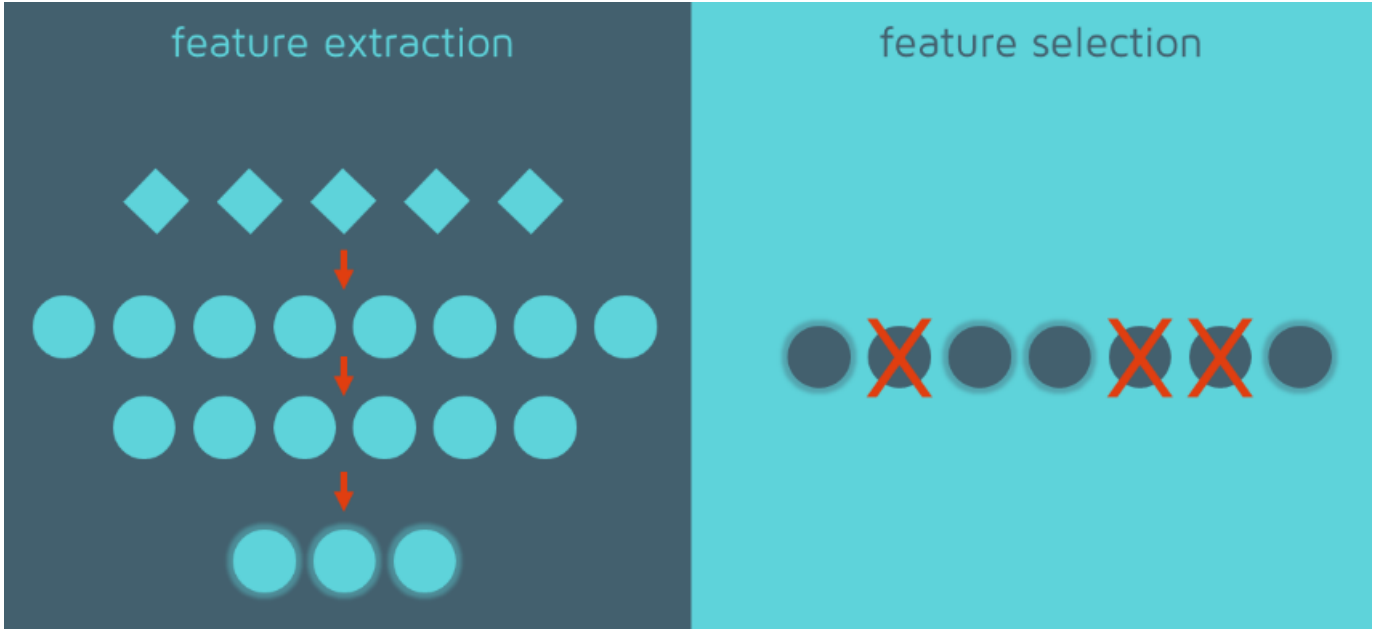

Sensitivity: C2 Internal

Reducción de la dimensionalidad: feature selection

Selección de características

Feature selection (Selección de características): Reducir la dimensionalidad elegiendo M variables de entre las N originales.

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} \xrightarrow[\text{feature selection}]{} \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{iM} \end{bmatrix}$$

Sensitivity: C2 Internal

Selección de características

Feature selection (Selección de características): Reducir la dimensionalidad elegiendo M variables de entre las N originales.

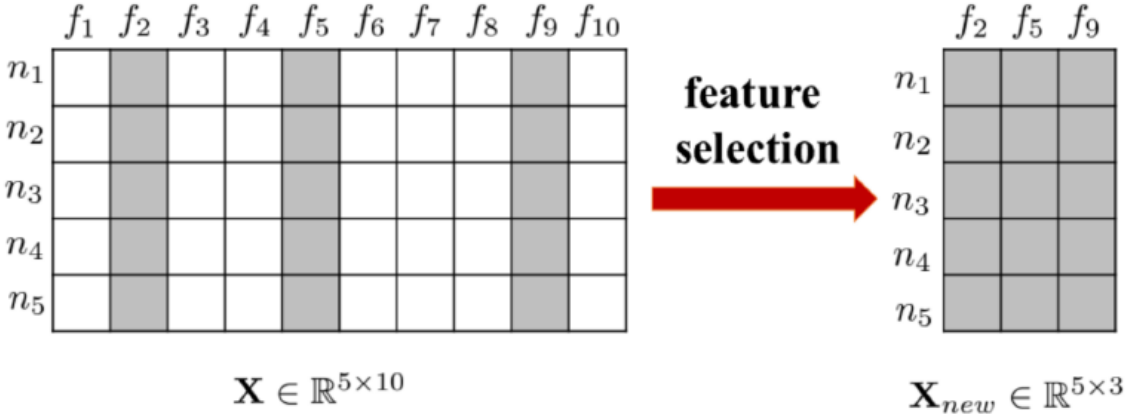

Sensitivity: C2 Internal

Selección de características

Feature selection (Selección de características): Ejemplo.

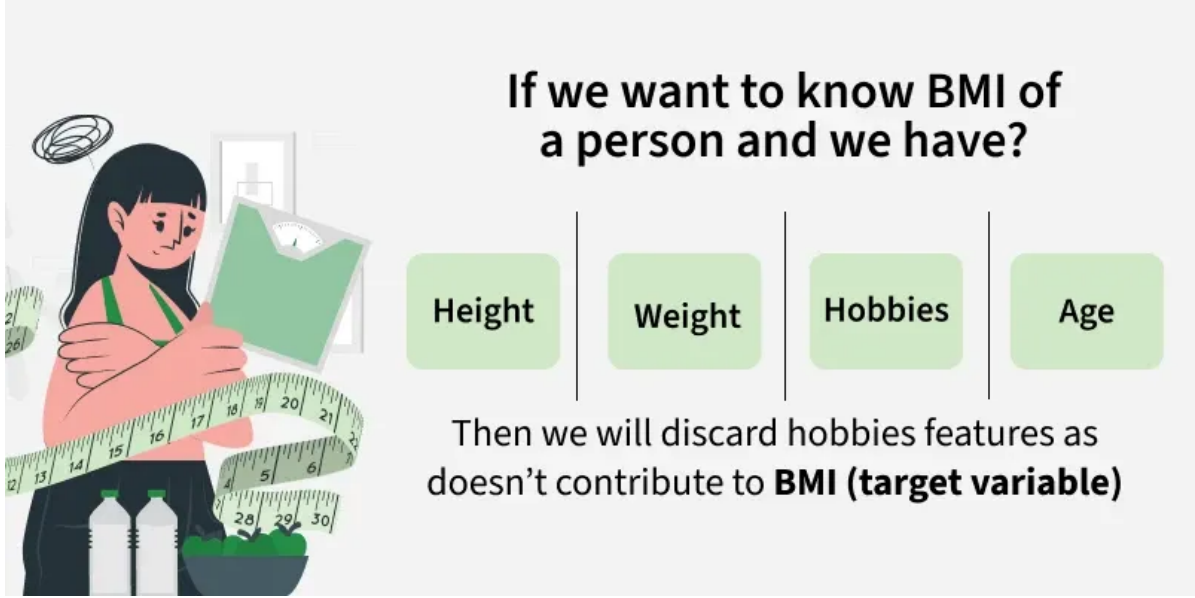

Sensitivity: C2 Internal

Selección de características

¿Que variables mantener?

Nos interesan las relevantes

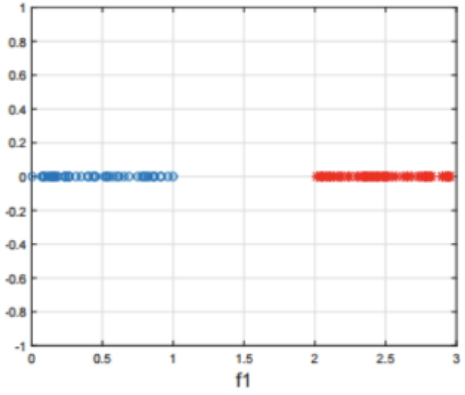

(a) relevant feature f_1

Sensitivity: C2 Internal

Selección de características

¿Que variables mantener?

Nos interesan las relevantes, pero no redundantes ni irrelevantes.

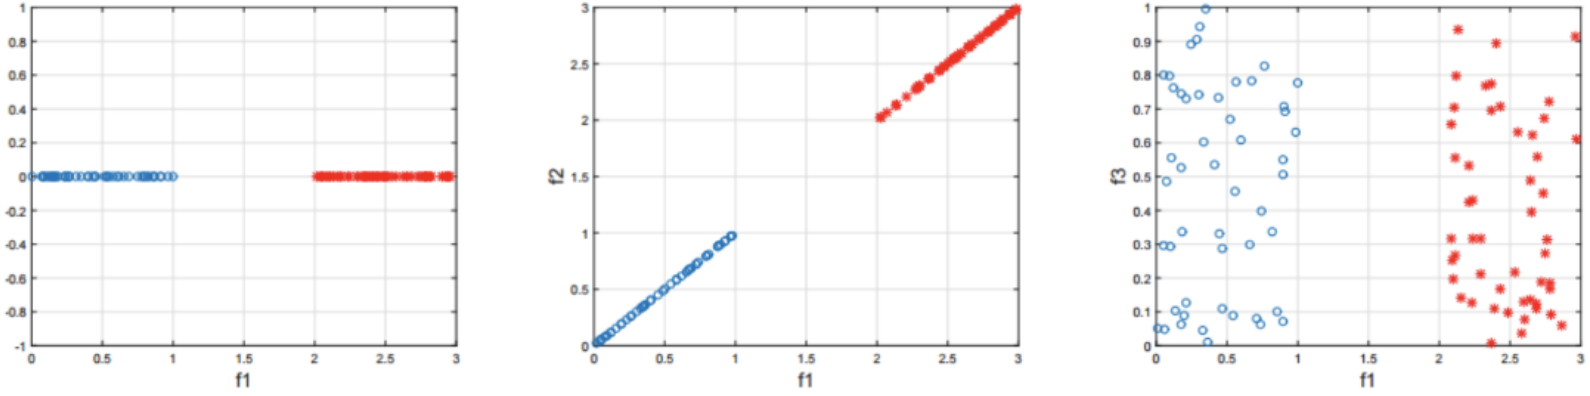

(a) relevant feature f_1 (b) redundant feature f_2 (c) irrelevant feature f_3

Sensitivity: C2 Internal

Selección de características

¿Cómo?

¿Que opciones tenemos?

Sensitivity: C2 Internal

Selección de características

¿Cómo?

Tres métodos principales: Métodos filter, wrapper o integrados.

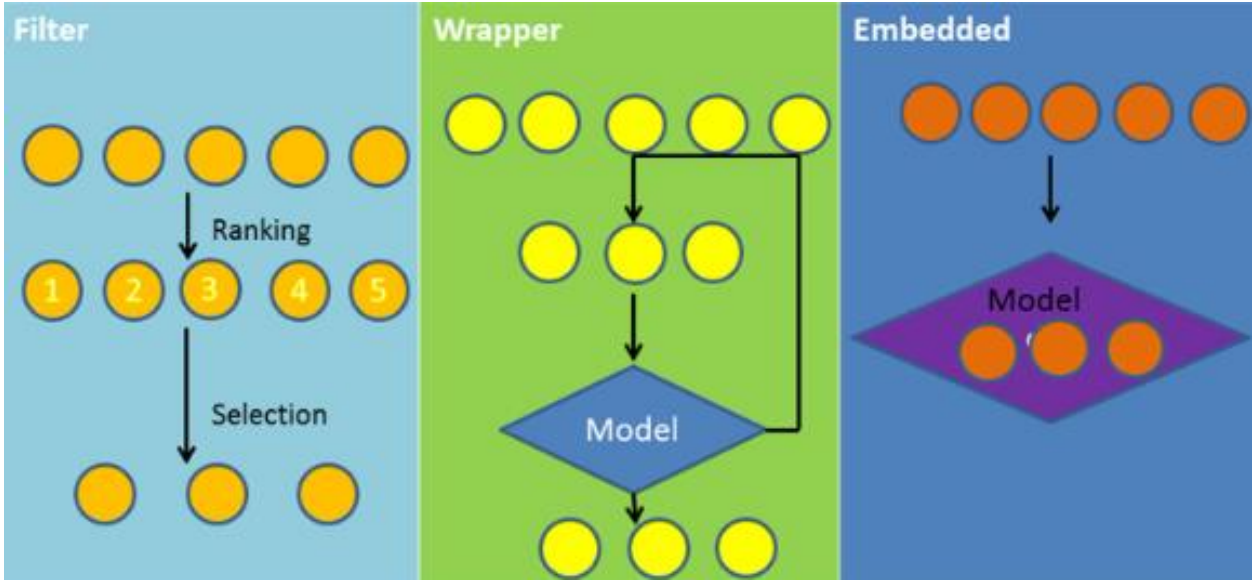

Sensitivity: C2 Internal

Selección de características: Filter

Métodos filter

Hacer un ranking de las variables (según el criterio elegido) para mantener solo las M mejores.

Utilizan una medida indirecta para evaluar la selección hecha.

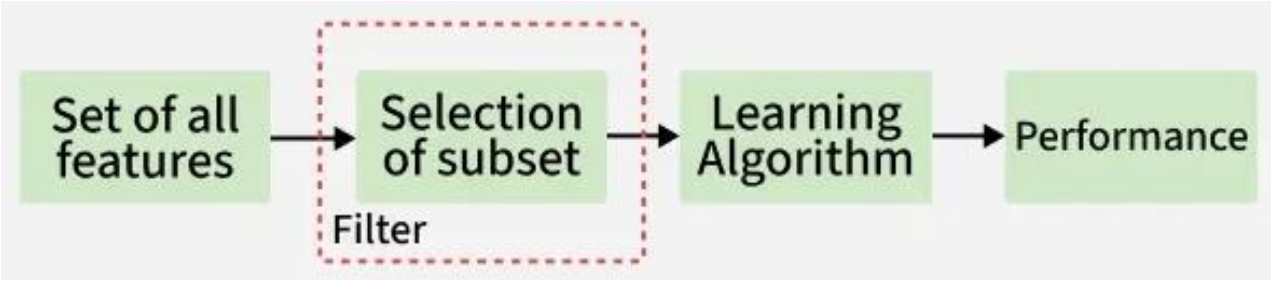

Sensitivity: C2 Internal

Selección de características: Filter

Métodos filter

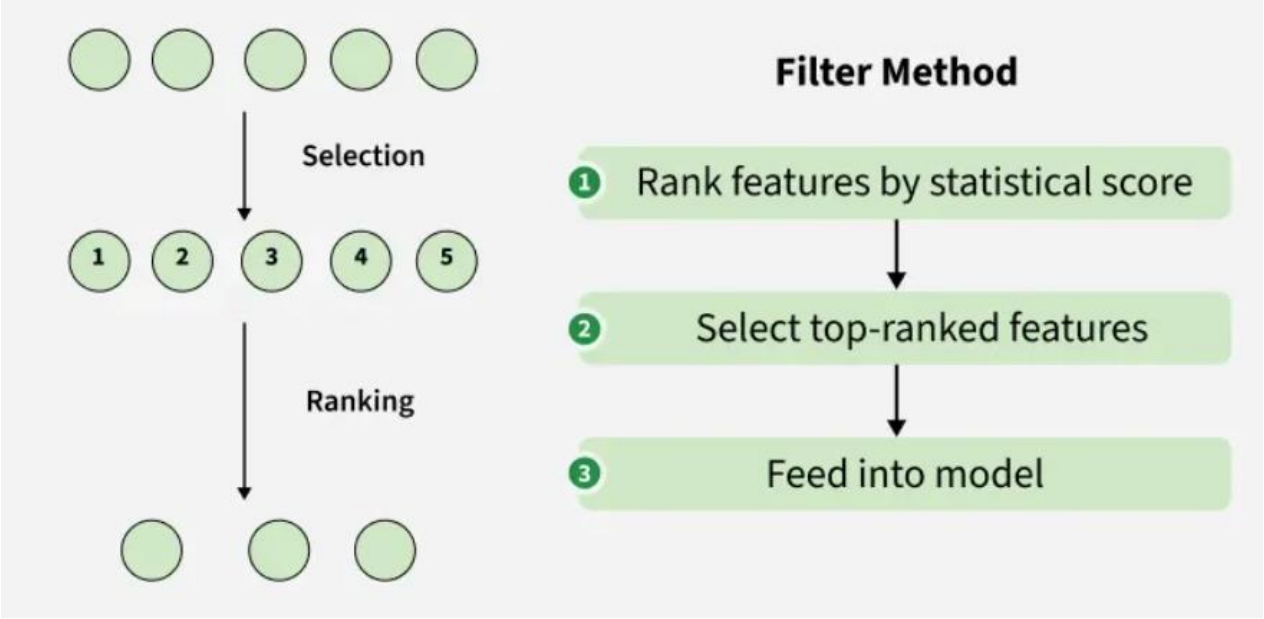

Sensitivity: C2 Internal

Selección de características: Filter

Métodos filter

Ejemplos:

- Correlación o información mutua entre cada par de características (redundancia).
- De cada característica con la variable dependiente (utilidad para el problema, si es superv.)

Common Filter Techniques

- **Information Gain:** Measures reduction in entropy when a feature is used.
- **Chi-square test:** Checks the relationship between categorical features.
- **Fisher's Score:** Ranks features based on class separability.
- **Pearson's Correlation Coefficient:** Measures linear relationship between two continuous variables.
- **Variance Threshold:** Removes features with very low variance.
- **Mean Absolute Difference:** Similar to variance threshold but uses absolute differences.
- **Dispersion ratio:** Ratio of arithmetic mean to geometric mean; higher values indicate useful features.

Sensitivity: C2 Internal

Selección de características: Filter

Métodos filter

Ventajas	Desventajas
Rápido y eficiente: Tienen un bajo coste computacional, lo que los hace ideales para conjuntos de datos masivos.	**No depende del modelo:** Al ignorar el algoritmo de aprendizaje final, pueden excluir variables que serían útiles en combinación con otras.
Fácil de implementar: Se basan en cálculos estadísticos simples (como correlación o ganancia de información).	**Elección de métrica:** El rendimiento varía drásticamente según si la métrica elegida captura correctamente la relación entre los datos.
No depende del modelo: Son universales; los resultados son robustos y no sufren de sobreajuste hacia un clasificador específico.	

Sensitivity: C2 Internal

Selección de características: Wrapper

Métodos wrapper

Analizar como impacta cada combinación de variables en un modelo concreto.

Analiza la relevancia de cada variable (o combinación) para la salida de un modelo.

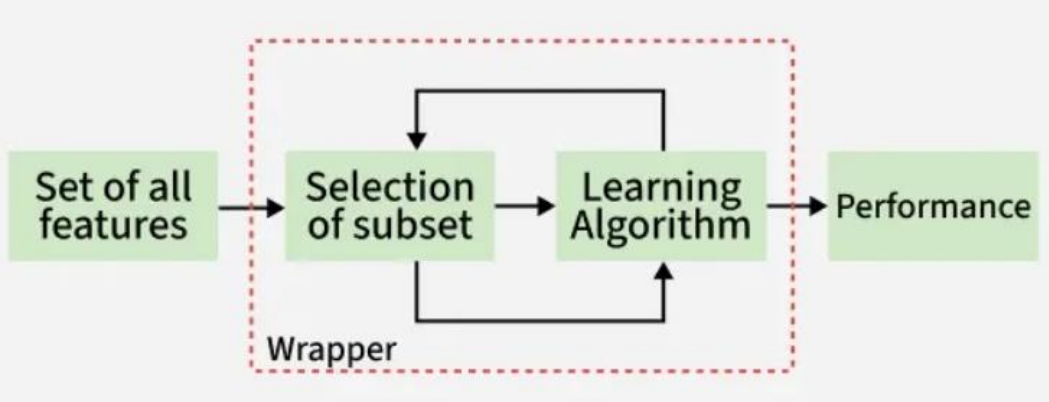

Sensitivity: C2 Internal

Selección de características: Wrapper

Métodos wrapper

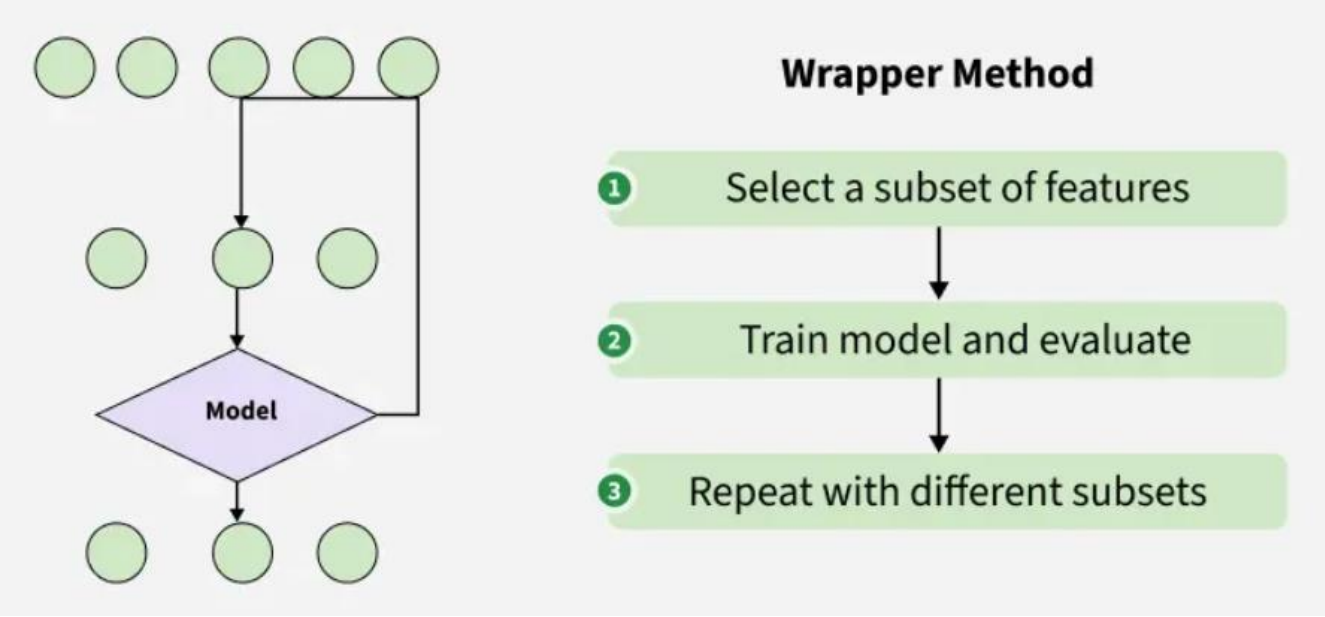

Sensitivity: C2 Internal

Selección de características: Wrapper

Métodos wrapper

Ejemplos:

- Análisis de sensibilidad en la salida del modelo eliminando la influencia de cada variable.
- Diferentes aproximaciones: recursivo variable a variable, por grupos de variables, etc.
- Mucho más rápido fijando a valor constante que haciendo combinaciones.

Sensitivity: C2 Internal

Selección de características: Wrapper

Métodos wrapper

Ventajas	Desventajas
Interacción con el modelo: Encuentran el subconjunto de variables que optimiza específicamente el rendimiento del algoritmo que se va a utilizar.	**Alto coste computacional:** Requieren entrenar y evaluar el modelo múltiples veces, lo que los hace lentos en conjuntos de datos grandes.
Capturan dependencias: A diferencia de los métodos *filter*, pueden detectar interacciones y relaciones complejas entre variables.	**Riesgo de sobreajuste (Overfitting):** Al optimizar tanto para un modelo y datos específicos, existe el riesgo de que los resultados no generalicen bien.
Mejor precisión: Generalmente ofrecen resultados superiores en términos de exactitud predictiva para el modelo seleccionado.	**Dependencia del modelo:** El subconjunto de variables elegido puede no ser útil si decides cambiar de algoritmo de aprendizaje.

Sensitivity: C2 Internal

Selección de características: Integrados

Métodos integrados (embedded)

Elección de las variables más importantes durante el entrenamiento del modelo.

Se necesita un modelo que nos aporte esta información.

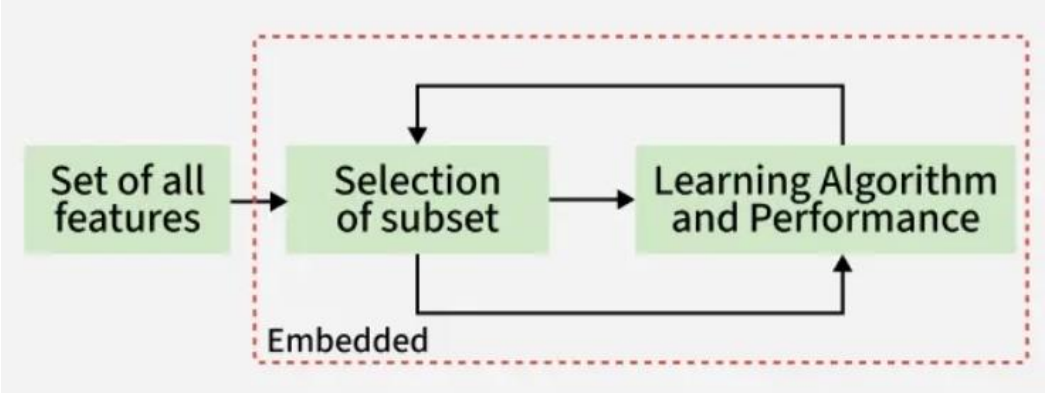

Sensitivity: C2 Internal

Selección de características: Integrados

Métodos integrados (embedded)

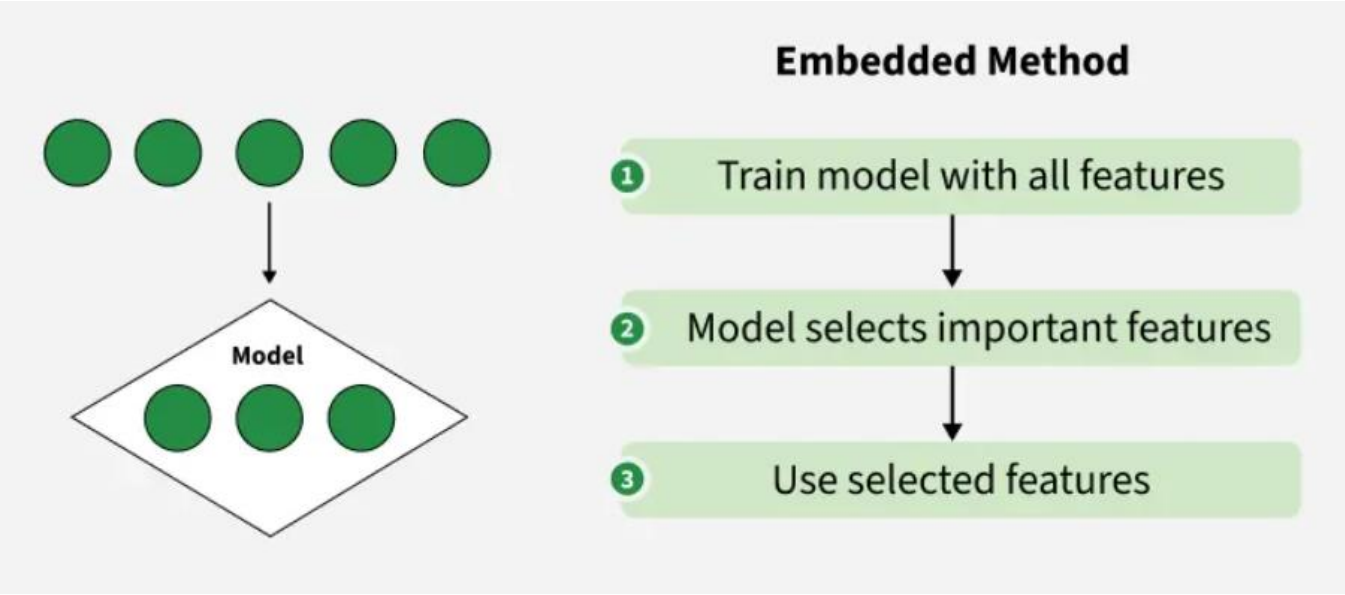

Sensitivity: C2 Internal

Selección de características: Integrados

Métodos integrados (embedded)

Ejemplos:

- Los modelos basados en árboles de decisión proporcionan información de importancia de las variables basado en la reducción de entropía.
- Regresiones Lasso o Ridge ponen a 0 los coeficientes de algunas variables.
- Gradient boosting da importancia de las variables basado en cuales reducen más el error.

Sensitivity: C2 Internal

Selección de características: Integrados

Métodos integrados (embedded)

Ventajas	Desventajas
Eficiencia equilibrada: Son mucho más rápidos que los métodos *Wrapper*, ya que la selección se realiza en un solo entrenamiento.	**Dependencia del modelo:** Al igual que los *Wrapper*, las variables seleccionadas son específicas para ese algoritmo concreto.
Capturan interacciones: Pueden detectar relaciones complejas entre variables, algo que los métodos *Filter* no logran.	**Limitación de algoritmos:** Solo puedes usarlos con modelos que tengan mecanismos de selección internos (como Lasso, Ridge o Árboles).
Menor riesgo de sobreajuste: Al incluir penalizaciones (regularización) en el aprendizaje, suelen generalizar mejor que los *Wrapper*.	**Complejidad de interpretación:** En modelos muy complejos (como redes neuronales), entender por qué se descartó una variable puede ser difícil.

Sensitivity: C2 Internal

Reducción de la dimensionalidad: feature extraction

Extracción de características

Feature extraction (Extracción de características): En lugar de elegir solo ciertas variables y eliminar el resto, se busca crear nuevas variables que sean combinaciones de las originales.

$$\begin{bmatrix} x_1 \\ x_2 \\ \\ \vdots \\ \\ x_N \end{bmatrix} \xrightarrow[\text{feature extraction}]{} \begin{bmatrix} x_1' \\ x_2' \\ \vdots \\ x_M' \end{bmatrix} = f\left(\begin{bmatrix} x_1 \\ x_2 \\ \\ \vdots \\ \\ x_N \end{bmatrix}\right)$$

Sensitivity: C2 Internal

Extracción de características

Feature extraction (Extracción de características):

De esta forma, aunque se reduzca la dimensionalidad, se intenta no perder nada de información relevante.

Las nuevas variables óptimas son aquellas que no aumentan el error.

En general, serán una combinación no-lineal de las variables originales y depende por complete de los datos y el problema.

Sensitivity: C2 Internal

Extracción de características

Feature extraction (Extracción de características):

Pero los métodos lineales son los más sencillos (aunque no siempre apropiados).

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} \xrightarrow[\text{linear feature extraction}]{} \begin{bmatrix} x_1' \\ x_2' \\ \vdots \\ x_M' \end{bmatrix} = \begin{bmatrix} w_{11} & w_{12} & \cdots & w_{1N} \\ w_{21} & w_{22} & \cdots & w_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ w_{M1} & w_{M2} & \cdots & w_{MN} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}$$

Sensitivity: C2 Internal

Extracción de características

Feature extraction (Extracción de características):

Los distintos métodos se basan en proyectar los datos en estos nuevos subespacios de menor dimension buscando máximizar o minimizer alguna métrica.

Ejemplos: max. varianza explicada, min. error...

$$\begin{bmatrix} x_1 \\ x_2 \\ \\ \vdots \\ \\ x_N \end{bmatrix} \xrightarrow[\text{linear feature extraction}]{} \begin{bmatrix} x_1' \\ x_2' \\ \vdots \\ x_M' \end{bmatrix} = \begin{bmatrix} w_{11} & w_{12} & \cdots & w_{1N} \\ w_{21} & w_{22} & \cdots & w_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ w_{M1} & w_{M2} & \cdots & w_{MN} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \\ \vdots \\ \\ x_N \end{bmatrix}$$

Sensitivity: C2 Internal

Extracción de características

Feature extraction (Extracción de características):

- Todos los métodos que vamos a utilizar son conocidos como "métodos espectrales" y están basado en resolver un problema de autovectores y autovalores de una matriz $\mathbf{F}$.
- Una vez definida la matriz de características $\mathbf{F}$, puesto que es una matriz cuadrada simétrica se puede escribir como:

$$\mathbf{F} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top$$

- Siendo $\mathbf{Q}$ una matriz que contiene los autovectores en sus columnas y $\mathbf{\Lambda}$ una matriz diagonal de tamaño una matriz que contiene los autovalores en su diagonal.
- Cada autovector $\mathbf{q}_i \in \mathbf{Q}$ tiene su correspondiente autovalor $\lambda_i \in \mathbf{\Lambda}$, tal que $\mathbf{F}\mathbf{q}_i = \lambda_i \mathbf{q}_i$

Sensitivity: C2 Internal

Extracción de características: PCA

PCA (Principal Component Analysis)

La técnica más famosa, conocida desde 1901.

Objetivo: Encontrar las proyecciones que maximizan la varianza preservada de los datos.

https://stats.stackexchange.com/questions/2691/making-sense-of-principal-component-analysis-eigenvectors-eigenvalues/140579#140579

Sensitivity: C2 Internal

Extracción de características: PCA

PCA (Principal Component Analysis)

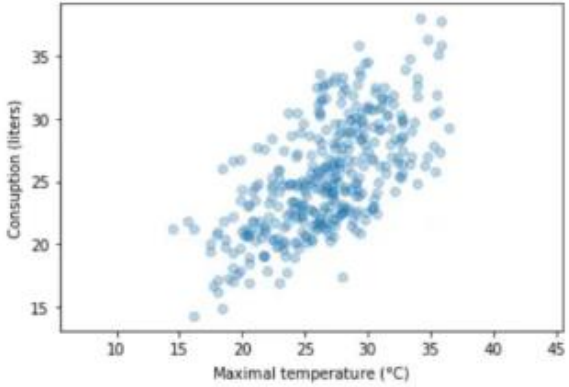

Sensitivity: C2 Internal

Extracción de características: PCA

PCA (Principal Component Analysis)

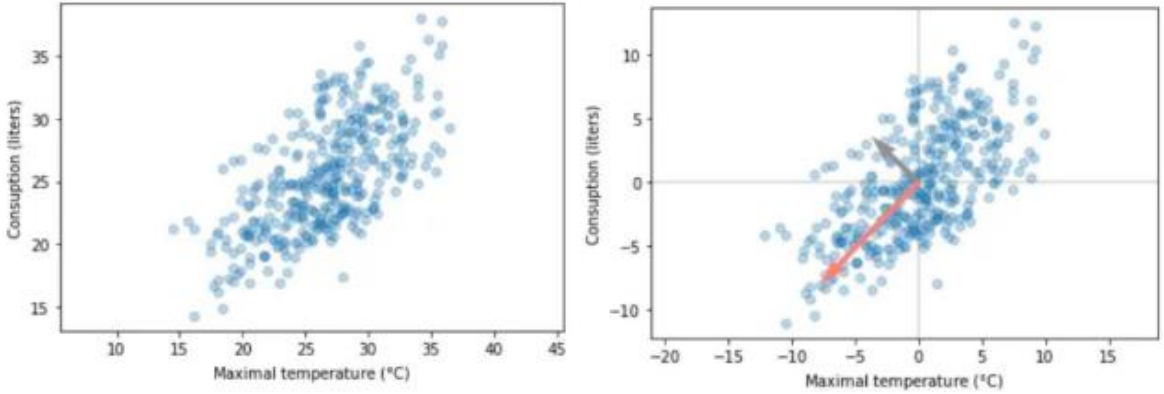

Sensitivity: C2 Internal

Extracción de características: PCA

PCA (Principal Component Analysis)

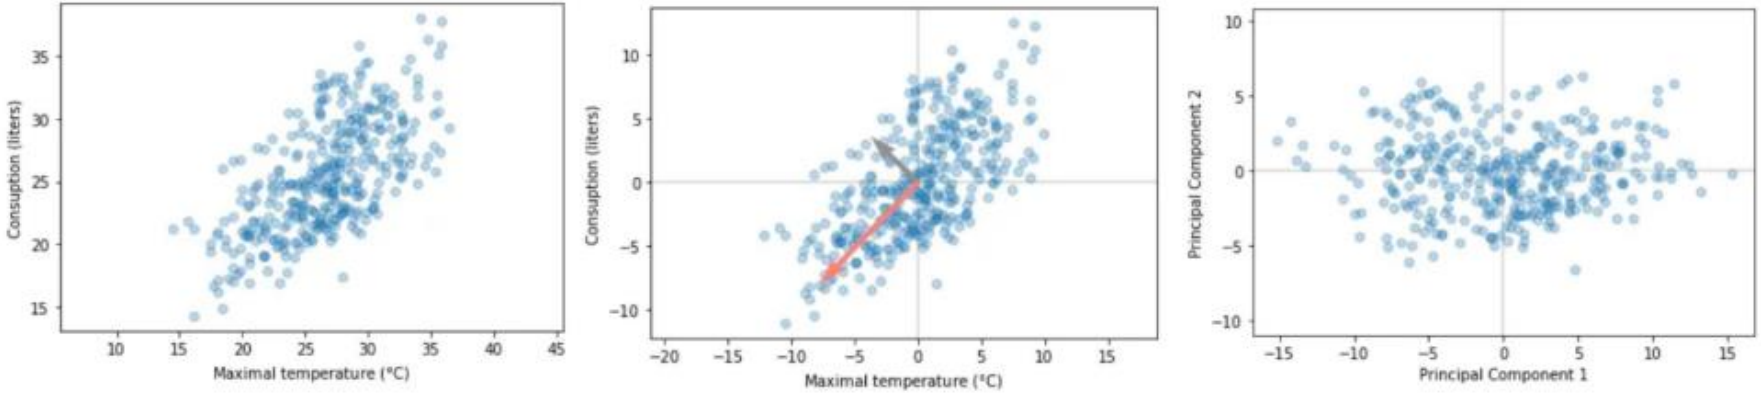

Sensitivity: C2 Internal

Extracción de características: PCA

PCA (Principal Component Analysis)

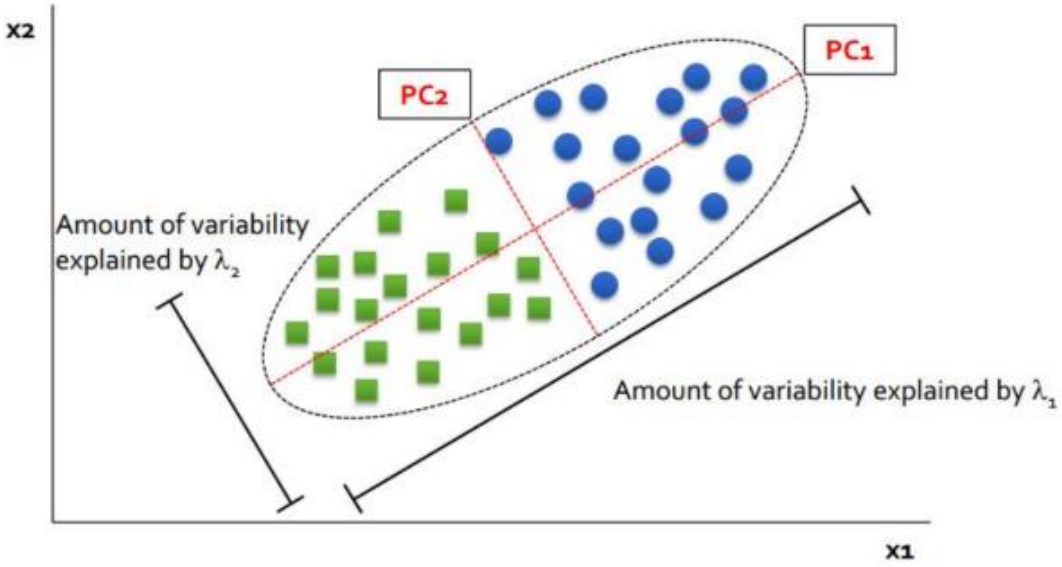

Sensitivity: C2 Internal

Extracción de características: PCA

PCA (Principal Component Analysis) matemáticamente...

Empirical covariance matrix

- Center data matrices (all columns have zero mean): $\mathbf{X} \rightarrow \tilde{\mathbf{X}}$
- Covariance is a measure of how much two variables change together
- (Empirical) Covariance matrix shows the joint variation of all pairs of variables:

$$\underbrace{\mathbf{C}_{xx}}_{d_x \times d_x} = \frac{1}{n} \underbrace{\tilde{\mathbf{X}}^\top}_{d_x \times n} \underbrace{\tilde{\mathbf{X}}}_{n \times d_x}$$

- *"Find projections maximizing the preserved variance of the data:"*

$$\begin{array}{lll} \text{PCA:} & \text{maximize:} & \mathrm{Tr}\{(\mathbf{XU})^\top(\mathbf{XU})\} = \mathrm{Tr}\{\mathbf{U}^\top\mathbf{C}_{xx}\mathbf{U}\} \\ & \text{subject to:} & \mathbf{U}^\top\mathbf{U} = \mathbf{I} \end{array}$$

- Using Lagrange multipliers to solve this constrained maximization problem, the solution (i.e. the columns of $\mathbf{U}$) is given by the eigenvectors $\mathbf{u}_k$ associated to the largest generalized eigenvalues λ_k:

$$\mathbf{C}_{xx}\mathbf{u}_k = \lambda_k \mathbf{u}_k \quad \longrightarrow \quad \mathbf{C}_{xx} = \mathbf{UDU}^\top$$

Sensitivity: C2 Internal

Extracción de características: PCA

PCA (Principal Component Analysis) matemáticamente...

Empirical covariance matrix

- Center data matrices (all columns have zero mean): $\mathbf{X} \rightarrow \tilde{\mathbf{X}}$
- Covariance is a measure of how much two variables change together
- (Empirical) Covariance matrix shows the joint variation of all pairs of variables:

$$\underbrace{\mathbf{C}_{xx}}_{d_x \times d_x} = \frac{1}{n} \underbrace{\tilde{\mathbf{X}}^\top}_{d_x \times n} \underbrace{\tilde{\mathbf{X}}}_{n \times d_x}$$

- *"Find projections maximizing the preserved variance of the data:"*

$$\text{PCA:} \quad \begin{array}{ll} \text{maximize:} & \mathrm{Tr}\{(\mathbf{XU})^\top(\mathbf{XU})\} = \mathrm{Tr}\{\mathbf{U}^\top \mathbf{C}_{xx}\mathbf{U}\} \\ \text{subject to:} & \mathbf{U}^\top\mathbf{U} = \mathbf{I} \end{array}$$

- Using Lagrange multipliers to solve this constrained maximization problem, the solution (i.e. the columns of $\mathbf{U}$) is given by the eigenvectors $\mathbf{u}_k$ associated to the largest generalized eigenvalues λ_k:

$$\mathbf{C}_{xx}\mathbf{u}_k = \lambda_k \mathbf{u}_k \quad \longrightarrow \quad \mathbf{C}_{xx} = \mathbf{UDU}^\top$$

- **Note that:**
  - the trace of a matrix $\mathrm{Tr}\{\cdot\}$ is the sum of its eigenvalues and also the cumulative variance of the projected dimensions
  - the eigenvectors $\mathbf{u}_k$ of $\mathbf{C}_{xx}$ are orthogonal, $\mathbf{u}_i^\top \mathbf{u}_j = 0$, and normal, $\mathbf{u}_i^\top \mathbf{u}_i = 1$ (so PCA is a simple rotation of the centered data)
  - the eigenvalues λ_k of $\mathbf{C}_{xx}$ represent the variance explained by each of the projected components ($\sigma_k^2 = \lambda_k$)
  - the rank of $\mathbf{C}_{xx} = \mathbf{X}^\top\mathbf{X}$ is limited by the number of training examples

Sensitivity: C2 Internal

Extracción de características: PCA

PCA (Principal Component Analysis): Ejemplo

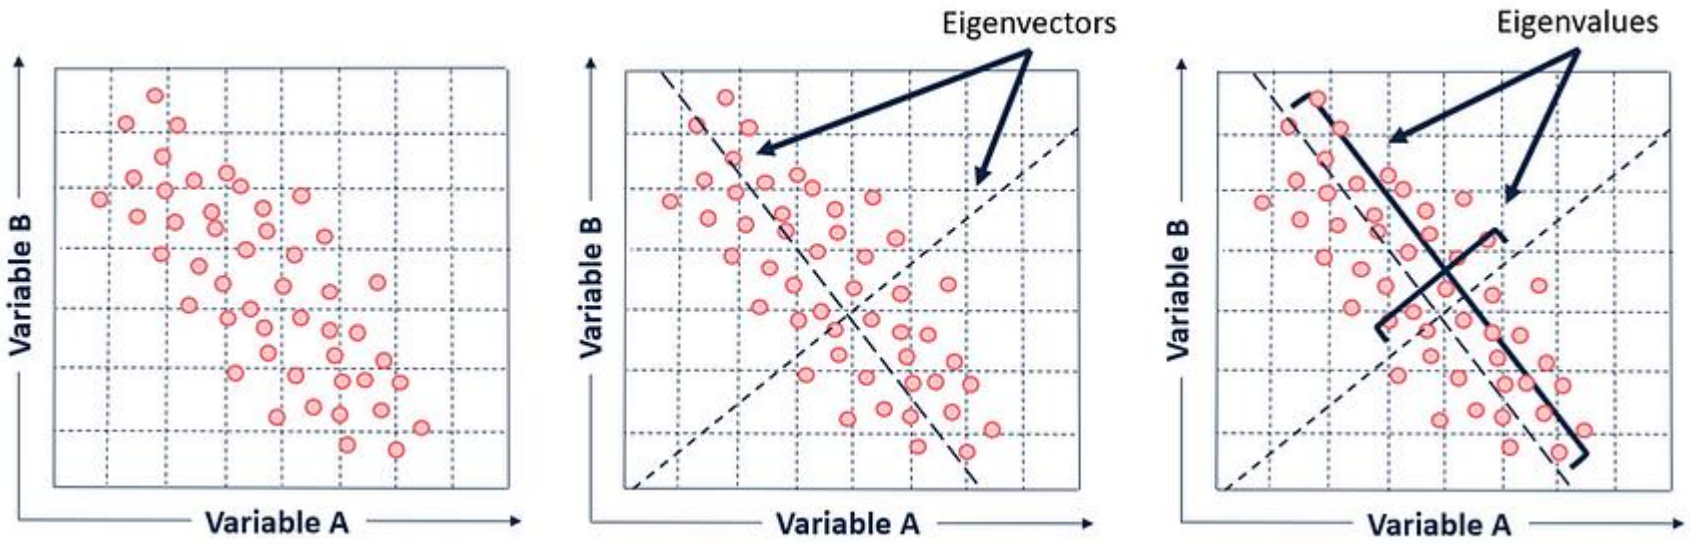

Sensitivity: C2 Internal

Extracción de características: PCA

PCA (Principal Component Analysis): Ejemplo

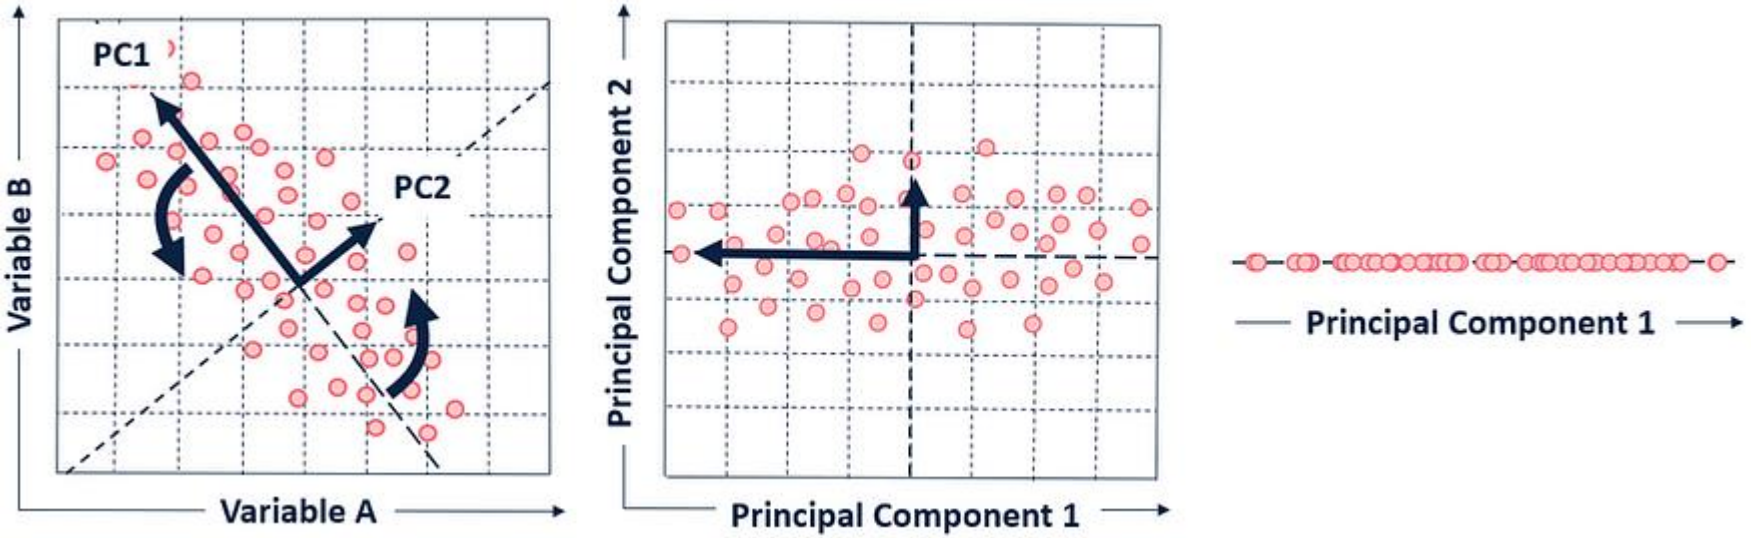

Sensitivity: C2 Internal

Extracción de características: PCA

PCA (Principal Component Analysis)

https://setosa.io/ev/principal-component-analysis/

Pros & cons:

- ✓ Simplicity
- ✓ Easy to understand
- ✓ Leads to convex optimization problems
- × Unsuitable for non-linear problems
- × More dimensions than points?

Sensitivity: C2 Internal

Extracción de características: ICA

ICA (Independent Component Analysis)

PCA a veces no es suficiente y necesitamos métodos más potentes o con otras restricciones.

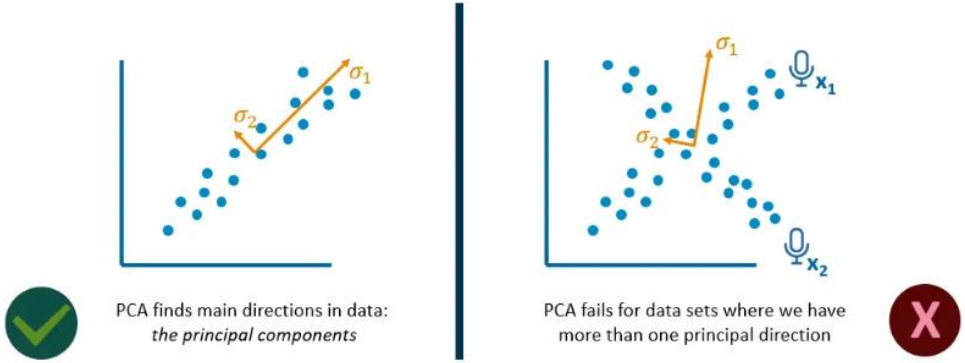

Sensitivity: C2 Internal

Extracción de características: ICA

ICA (Independent Component Analysis)

ICA busca separar los datos en las señales/direcciones fundamentales independientes entre sí.

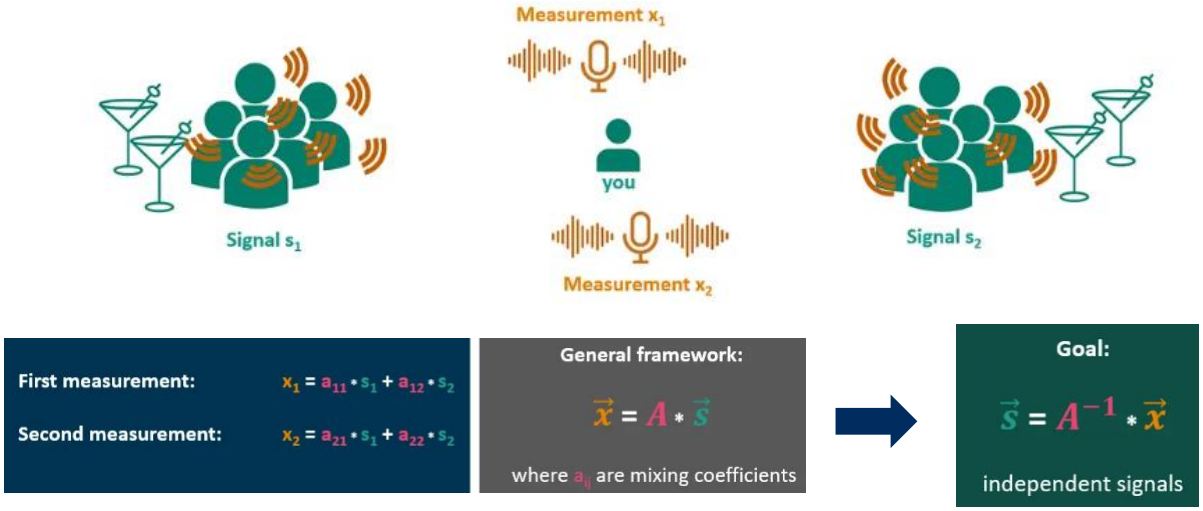

Sensitivity: C2 Internal

Extracción de características: ICA

ICA (Independent Component Analysis)

Assume there exist independent signals: $S = [s_1(t), s_2(t), \dots, s_N(t)]$

Linear combinations of signals: $Y(t) = A\,S(t)$

- Both A and S are unknown
- A is called the mixing matrix

Goal of ICA: recover original signals, S(t) from Y(t)

- Ex. find a linear transformation, L, ideally A^{-1} st. LY(t) = S(t)

Sensitivity: C2 Internal

Extracción de características: ICA

ICA (Independent Component Analysis)

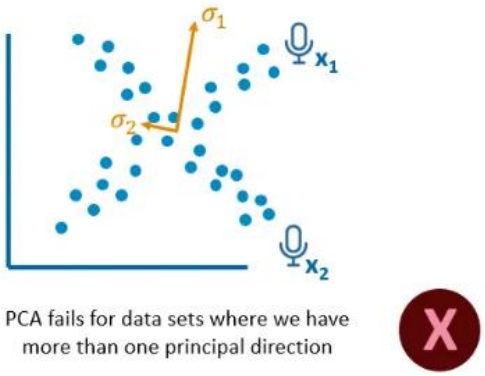

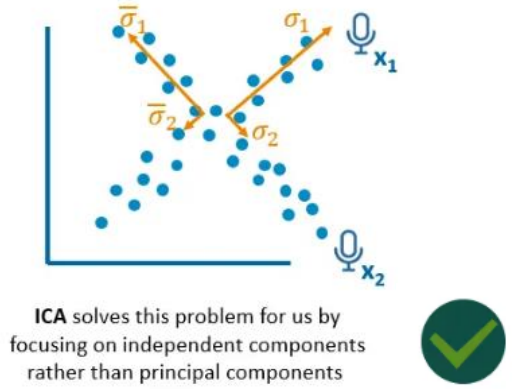

Sensitivity: C2 Internal

Extracción de características: ICA

ICA (Independent Component Analysis)

Mientras que PCA solo descorrelaciona, ICA es más estricto y busca direciones que sean completamente independientes (por ejemplo, que su mutual information sea 0), aunque no sean ortogonales entre sí.

Además, mientras que PCA da más importancia a unas direcciones, para el ICA todas son igual de importantes.

Sensitivity: C2 Internal

Extracción de características: ICA

ICA (Independent Component Analysis)

Característica	PCA (Principal Component Analysis)	ICA (Independent Component Analysis)
Objetivo Principal	Maximizar la varianza explicada y descorrelacionar los datos.	Encontrar componentes que sean estadísticamente independientes.
Criterio Estadístico	Se basa en el segundo momento (covarianza). Busca ortogonalidad.	Se basa en momentos de orden superior (curtosis). Busca no-gaussianidad.
Relación entre Ejes	Los componentes son siempre perpendiculares (ortogonales) entre sí.	Los componentes no tienen por qué ser ortogonales; busca las "fuentes puras".

Sensitivity: C2 Internal

Extracción de características: Otros

Existen muchos más métodos:

MDS (Multi-Dimensional Scaling): Busca proyectar los datos a un espacio donde la distancia Euclidea entre muestras se mantenga respecto al espacio original, es decir, busca preservar las distancias.

Sensitivity: C2 Internal

Extracción de características: LDA

LDA (Linear Discriminant Analysis)

Es supervisado, usa información de la variable a predecir.

PCA:
component axes that maximize the variance

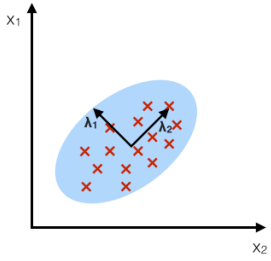

LDA:
maximizing the component axes for class-separation

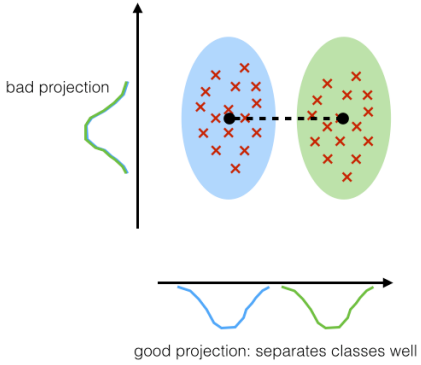

Sensitivity: C2 Internal

Extracción de características: LDA

LDA (Linear Discriminant Analysis)

Es supervisado, usa información de la variable a predecir.

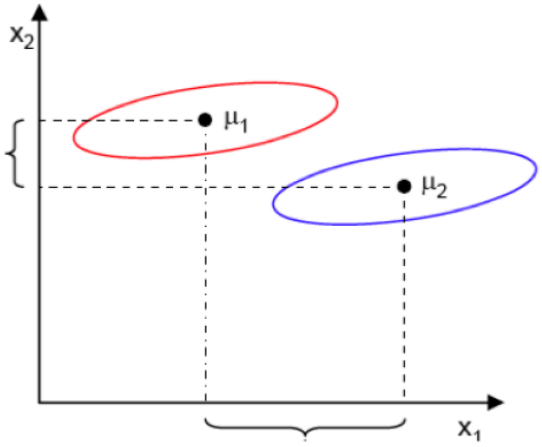

Sensitivity: C2 Internal

Extracción de características: LDA

LDA (Linear Discriminant Analysis)

Es supervisado, usa información de la variable a predecir.

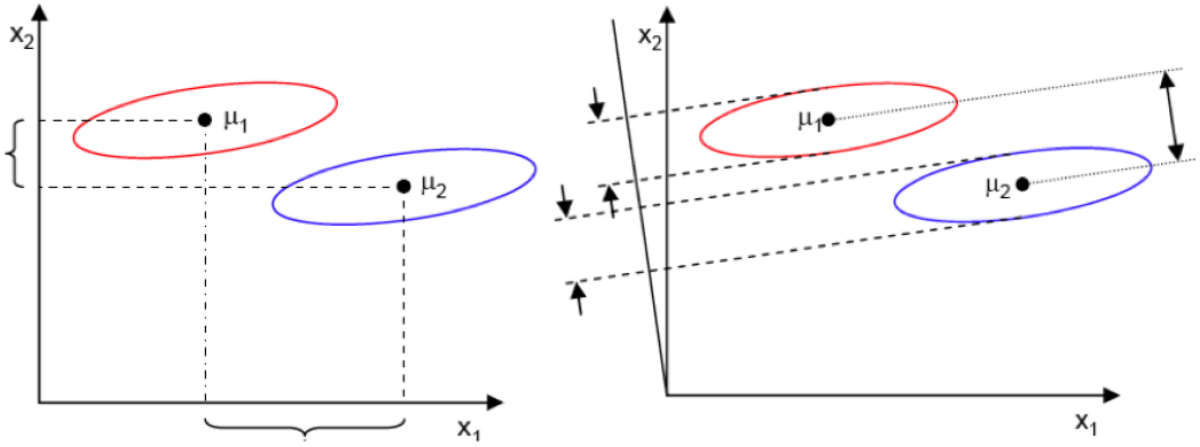

Sensitivity: C2 Internal

Extracción de características: LDA

LDA (Linear Discriminant Analysis)

Es supervisado, usa información de la variable a predecir.

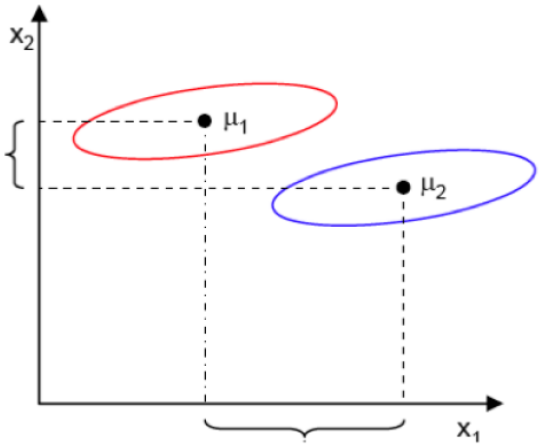

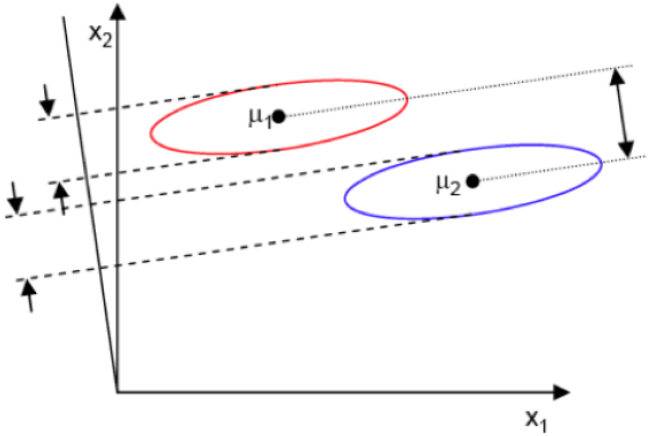

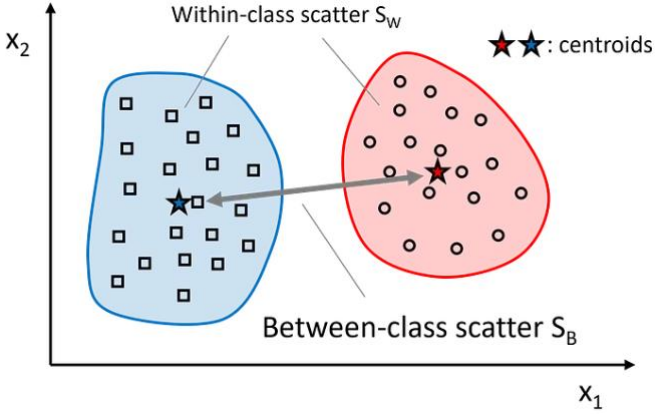

Sensitivity: C2 Internal

Extracción de características: LDA

LDA (Linear Discriminant Analysis)

Se buscan las direcciones que maximizan el ratio de entre-clases sobre intra-clases.

$$\mathbf{S}_B = \sum_{k=1}^{C} n_k (\boldsymbol{\mu}_k - \boldsymbol{\mu})(\boldsymbol{\mu}_k - \boldsymbol{\mu})^T$$

$$\mathbf{S}_W = \sum_{k=1}^{C} \sum_{i \in \mathcal{C}_k} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T$$

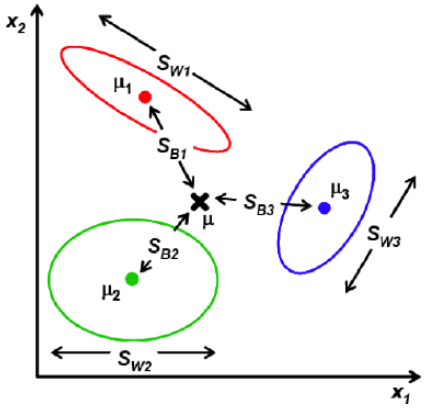

Sensitivity: C2 Internal

Extracción de características: LDA

LDA (Linear Discriminant Analysis)

Característica	PCA (Principal Component Analysis)	ICA (Independent Component Analysis)	LDA (Linear Discriminant Analysis)
Tipo de Aprendizaje	No supervisado.	No supervisado.	**Supervisado** (usa etiquetas)
Objetivo Principal	Maximizar la **varianza** explicada y descorrelaciona.	Encontrar **fuentes independientes.**	Maximizar la **separabilidad entre clases.**
Criterio Matemático	Covarianza, busca ortogonalidad.	Independencia (momentos de orden superior).	Ratio de varianza "entre clases" vs varianza "dentro de clase“.
Componentes finales	Ejes ortogonales de mayor dispersión.	"Fuentes puras" que generaron la mezcla.	Direcciones que mejor discriminan los grupos.

Sensitivity: C2 Internal

Extracción de características: Manifold learning

Hasta ahora todos los métodos eran lineales...
¿Que hacemos si nuestros datos son claramente no linales?

https://setosa.io/ev/principal-component-analysis/

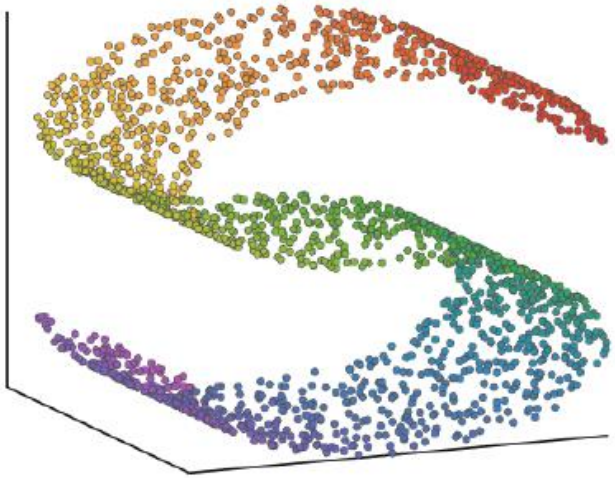

Sensitivity: C2 Internal

Extracción de características: Manifold learning

Aunque parece tridimensional, los datos en realidad se distribuyen a lo largo de una superficie bidimensional.

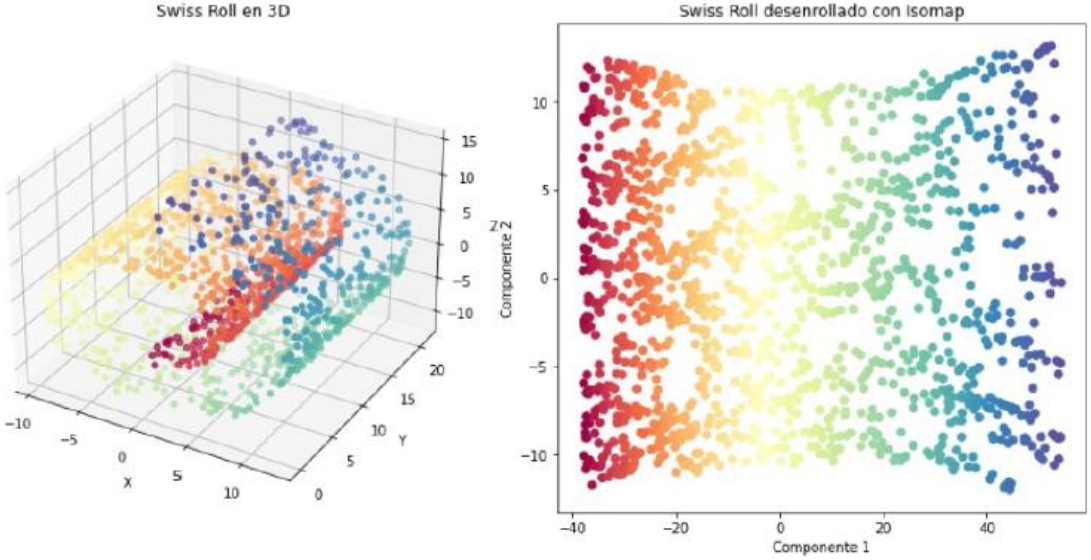

Sensitivity: C2 Internal

Extracción de características: Manifold learning

Necesitamos métodos no lineales.

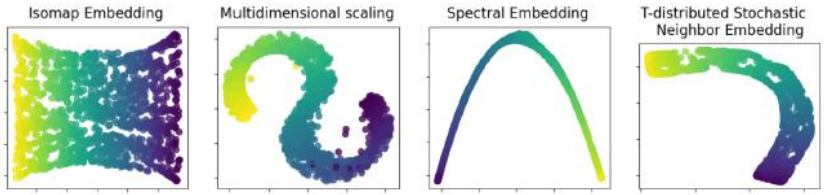

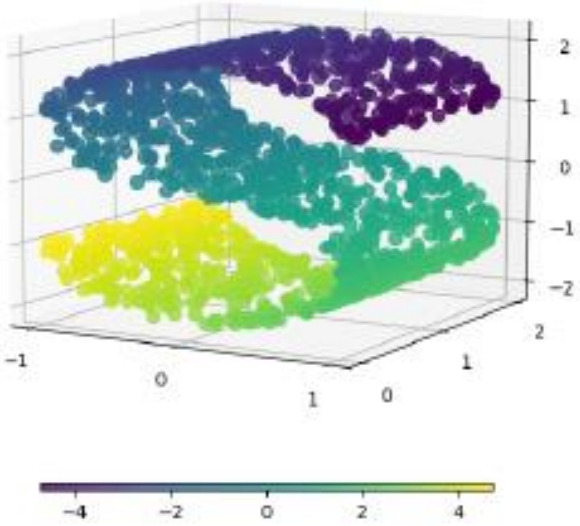

Sensitivity: C2 Internal

Extracción de características: Manifold learning

Estos métodos se conocen como manifold learning: aprender las características geométricas y topologicas de los datos.

Son mucho más potentes que los métodos linales como PCA, ICA, LDA...

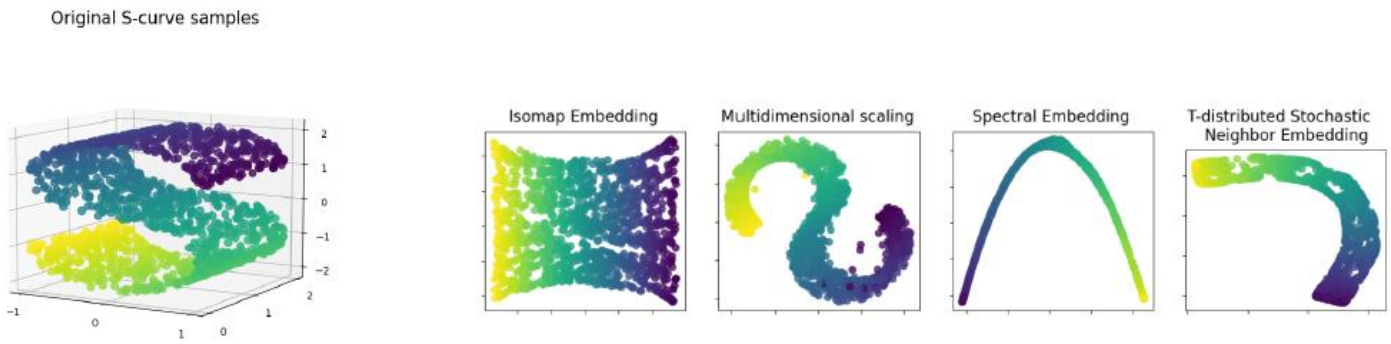

Sensitivity: C2 Internal

Extracción de características: Manifold learning

Locally Linear Embedding:

Se basa en modelizar el manifold de manera local.

Tiene como parámetro el número de vecinos para considerar la vecindad de cada punto.

Exige mantener la geometría local en el proceso de optimización.

Sensitivity: C2 Internal

Extracción de características: Manifold learning

Locally Linear Embedding:

Fig. 2. Steps of locally linear embedding: (1) Assign neighbors to each data point $\vec{X}_i$ (for example by using the K nearest neighbors). (2) Compute the weights W_{ij} that best linearly reconstruct $\vec{X}_i$ from its neighbors, solving the constrained least-squares problem in Eq. 1. (3) Compute the low-dimensional embedding vectors $\vec{Y}_i$ best reconstructed by W_{ij}, minimizing Eq. 2 by finding the smallest eigenmodes of the sparse symmetric matrix in Eq. 3. Although the weights W_{ij} and vectors Y_i are computed by methods in linear algebra, the constraint that points are only reconstructed from neighbors can result in highly nonlinear embeddings.

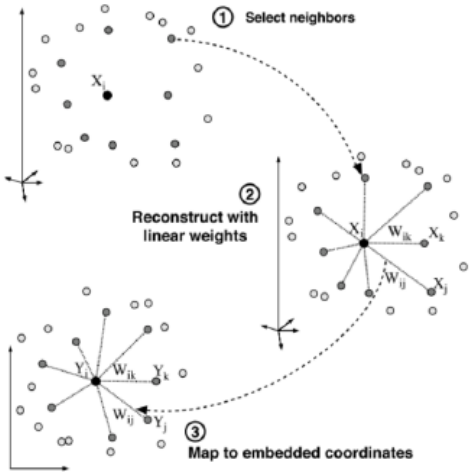

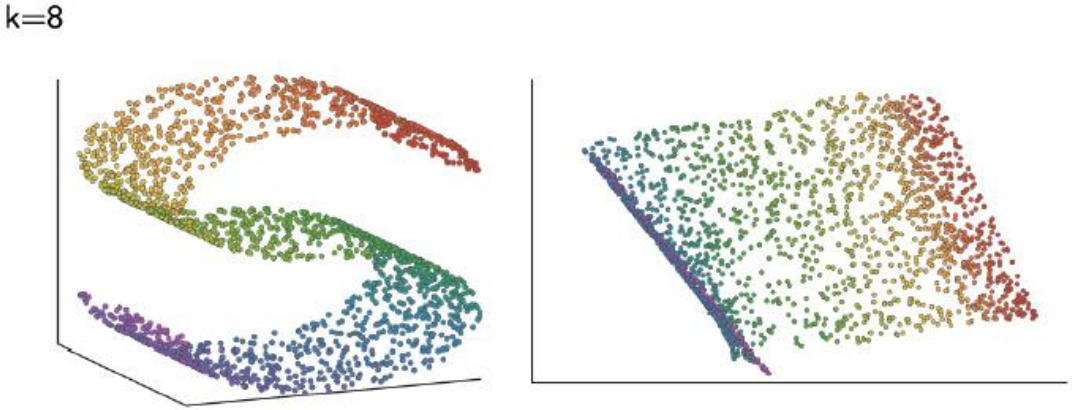

Sensitivity: C2 Internal

Extracción de características: Manifold learning

Local PCA: Ir aplicando PCA a subgrupos de datos, de forma que las direcciones principales extraidas vayan cambiando según la posición de los datos.

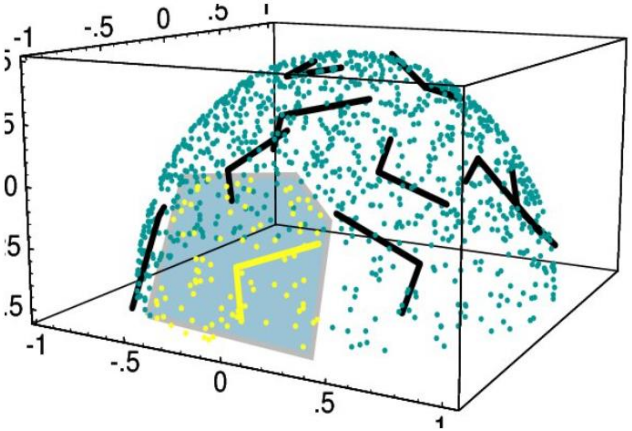

Sensitivity: C2 Internal

Extracción de características: Manifold learning

ISOMAP

Basado en MDS (que utilizaba la distancia euclidea entre puntos).

Se calcula la distancia entre puntos, pero “a lo largo” del manifold midiendo la distancia entre puntos siguiendo los datos.

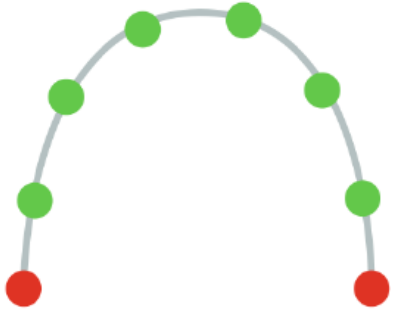

Sensitivity: C2 Internal

Extracción de características: Manifold learning

ISOMAP

Basado en MDS (que utilizaba la distancia euclidea entre puntos).

Se calcula la distancia entre puntos, pero “a lo largo” del manifold midiendo la distancia entre puntos siguiendo los datos.

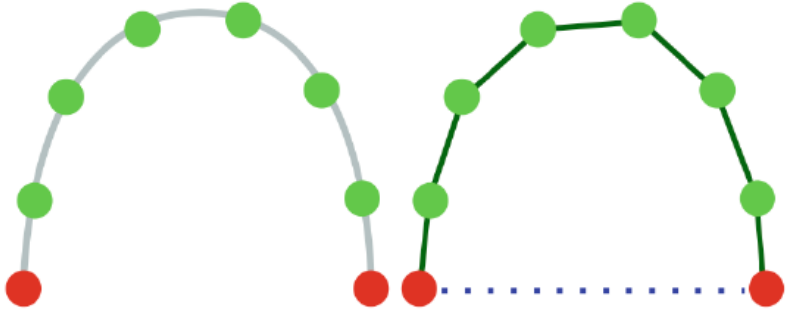

Sensitivity: C2 Internal

Extracción de características: Manifold learning

ISOMAP

La distancia calculada a lo largo del manifod es mucho mas robusta y exacta en conjuntos de datos con una estructura no lineal.

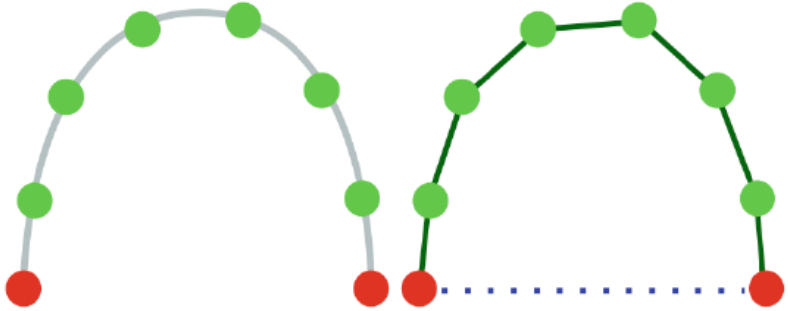

Sensitivity: C2 Internal

Extracción de características: Manifold learning

ISOMAP

Se calculan las distancias entre puntos usando la distancia de Dijkstra: distancia más corta entre dos puntos pero que pasa por los puntos más cercanos entre sí.

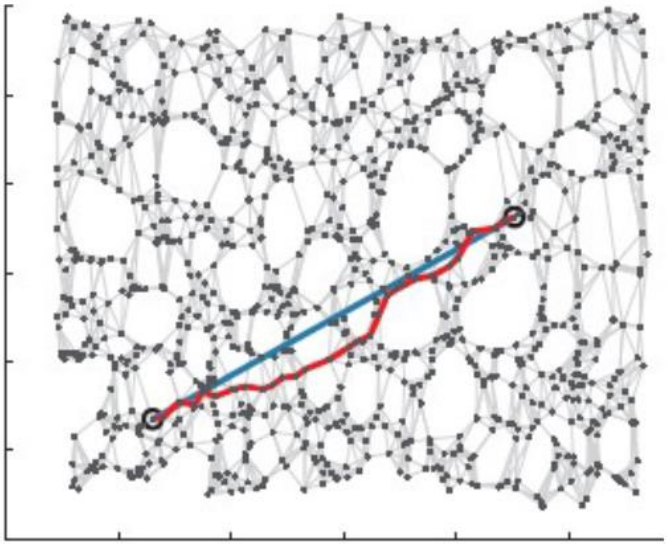

$$\varphi(\mathbf{x}_i, \mathbf{x}_j) \equiv \textit{Distancia de Dijkstra}$$

Sensitivity: C2 Internal

Extracción de características: Manifold learning

ISOMAP

Busca una transformación a menor dimensiones manteniendo las distancias entre cada par de puntos.

Si tenemos 1000 datos, busca mantener 1000×1000 restricciones de distancias.

Distancias muy grandes tienen mucho más peso numérico que las distancias pequeñas, por lo que Isomap sacrifica la precisión de los vecinos cercanos.

Sensitivity: C2 Internal

Extracción de características: Manifold learning

ISOMAP

Distancias muy grandes tienen mucho más peso numérico que las distancias pequeñas, por lo que Isomap sacrifica la precisión de los vecinos cercanos.

Por esto se dice que ISOMAP mantiene la estructura global.

Sensitivity: C2 Internal

Extracción de características: Manifold learning

ISOMAP

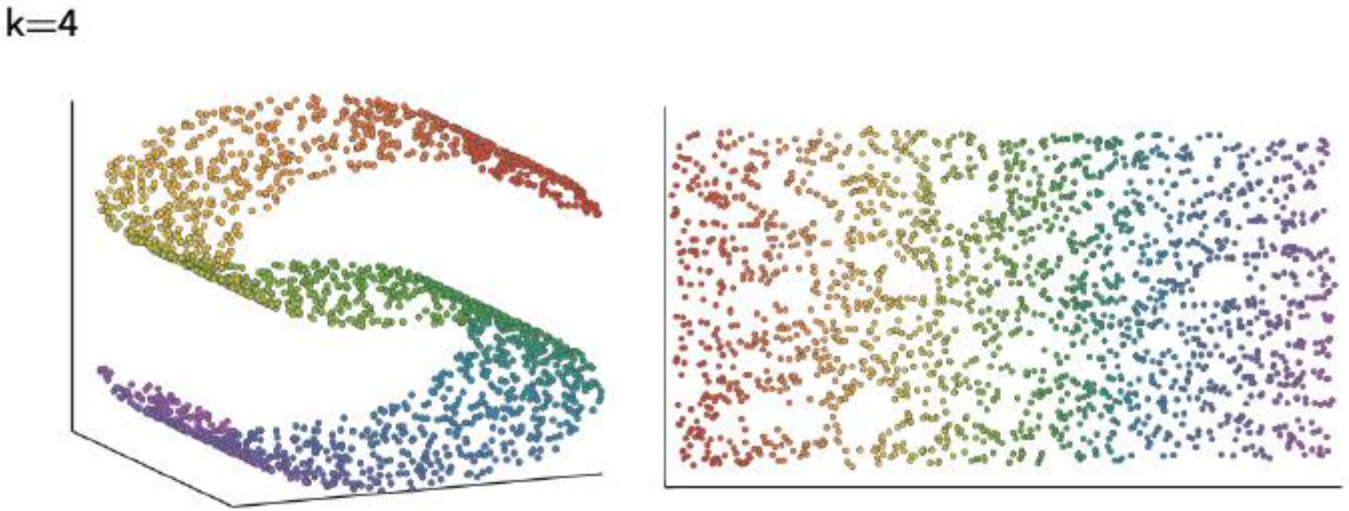

Conserva bien la estructura global de los datos.

Sensitivity: C2 Internal

Extracción de características: Manifold learning

t-distributed Stochastic Neighbor Embedding (t-SNE)

Se basa en buscar que las probabilidades condicionales en el dominio original sean parecidas en el dominio otro.

Sensitivity: C2 Internal

Extracción de características: Manifold learning

t-distributed Stochastic Neighbor Embedding (t-SNE)

Calcula la probabilidad de que un punto sea vecino a otro, según como de lejos está. Si dos puntos están cerca, tienen una alta probabilidad de ser “vecinos”.

Hay que elegir la anchura/número de datos que observa cada dato para construir sus vecinos probables: perplexity.

Se intentan mantener estas probabilidades en el nuevo espacio.

Sensitivity: C2 Internal

Extracción de características: Manifold learning

t-distributed Stochastic Neighbor Embedding (t-SNE)

Matemáticamente:

Se define la probabilidad en el espacio original de que un punto sea vecino de otro:

$$p_{j|i} = \frac{exp(-||x_i - x_j||^2/2\sigma_i^2)}{\sum_{k \neq i} exp(-||x_i - x_k||^2/2\sigma_i^2)}$$

Disimilaridad: Qué tan diferentes o NO similares son dos puntos.

$$d_{ij}^2 = \frac{\left\|x_i - x_j\right\|^2}{2\sigma_i^2}$$

Sensitivity: C2 Internal

Extracción de características: Manifold learning

t-distributed Stochastic Neighbor Embedding (t-SNE)

Matemáticamente:

A continuación se inicializan aleatoriamente los puntos en el espacio de salida y se define una nueva distribución del probabilidades:

$$q_{ij} = \frac{(1 + ||y_i - y_j||^2)^{-1}}{\sum_{k \neq l}(1 + ||y_k - y_l||^2)^{-1}}$$

Busca minimizar: $$KL(P||Q) = \sum_i \sum_{j \neq i} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

Sensitivity: C2 Internal

Extracción de características: Manifold learning

t-distributed Stochastic Neighbor Embedding (t-SNE)

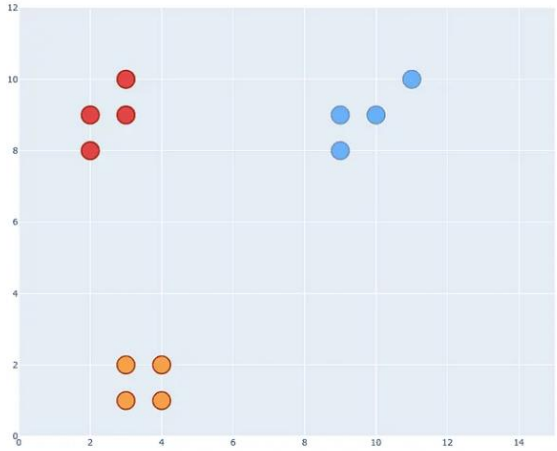

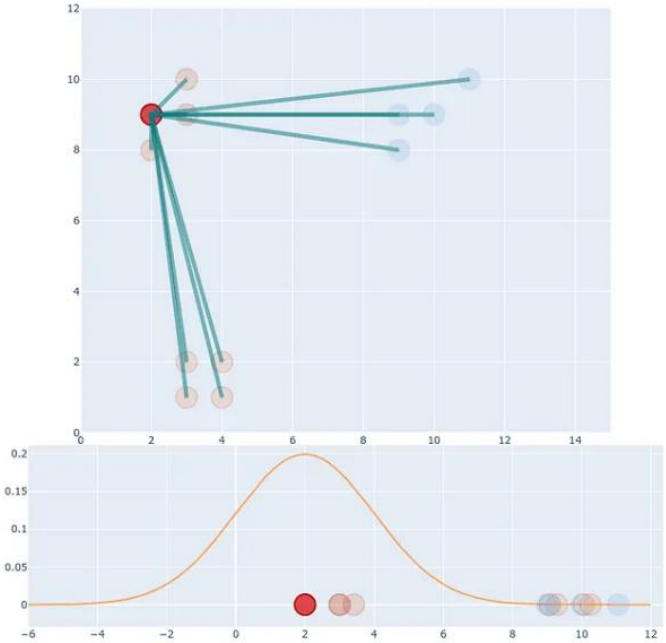

Sensitivity: C2 Internal

Extracción de características: Manifold learning

t-distributed Stochastic Neighbor Embedding (t-SNE)

Iterativamente, se va buscando este espacio que mantiene las probabilidades lo mas parecidas posibles al espacio original.

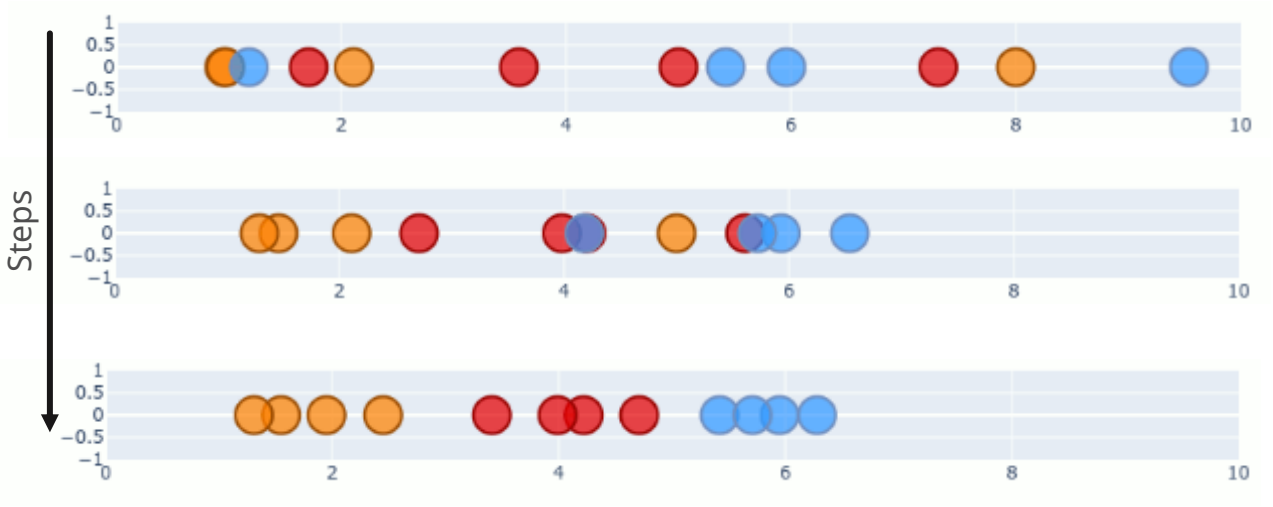

Sensitivity: C2 Internal

Extracción de características: Manifold learning

t-distributed Stochastic Neighbor Embedding (t-SNE)

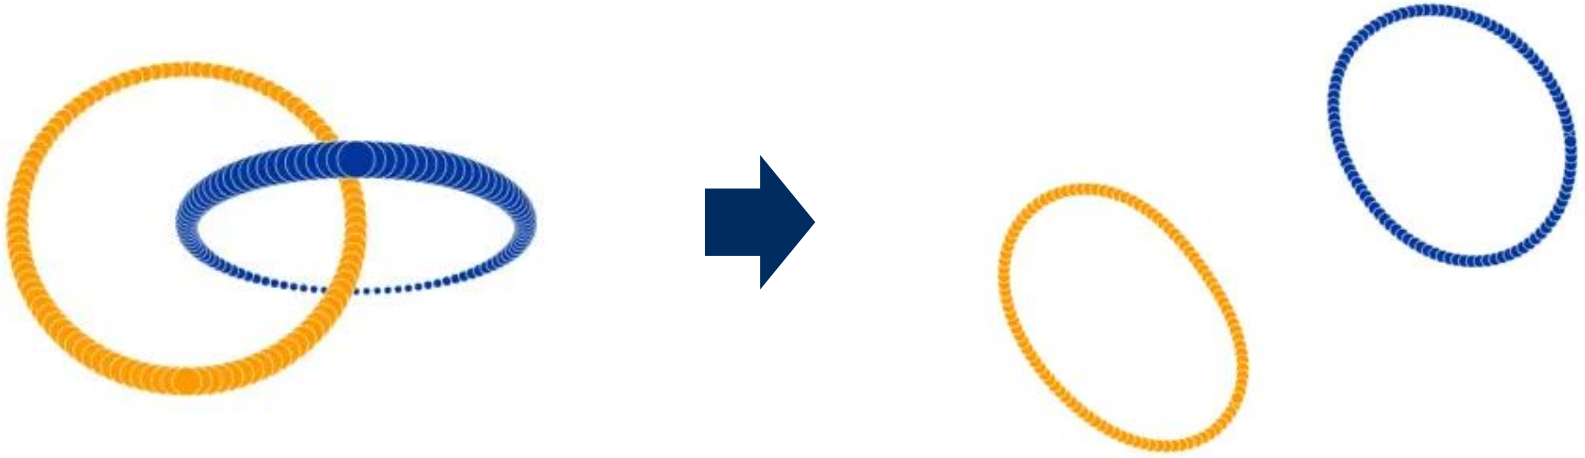

También depende del número de vecinos elegido: “perplexity”.
Conserva bien la estructura local de los datos.

Sensitivity: C2 Internal

Extracción de características: Manifold learning

UMAP (Uniform Manifold Approximation and Projection)

Combina lo mejor de ISOMAP y t-SNE, logrando preservar las estructuras locales y la estructura global.

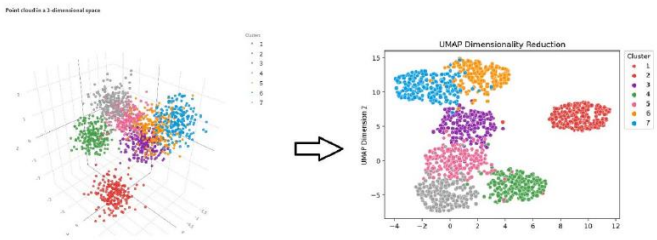

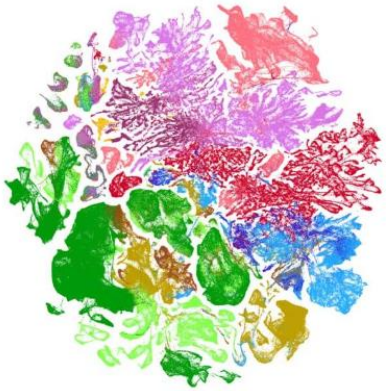

Sensitivity: C2 Internal

Extracción de características: Manifold learning

UMAP (Uniform Manifold Approximation and Projection)

Crea una red de conexiones (grafo) para cada punto de forma probabilistica, pero usando decaimiento exponencial (nunca es 0).

Pesos de las conexiones (afinidades):

Las conexiones entre los nodos (puntos) se ponderan con una función de afinidad basada en la distancia entre puntos xi y xj:

$$w_{ij} = e^{-\frac{d(x_i, x_j) - \rho_i}{\sigma_i}}$$

- Donde:
  - $d(x_i, x_j)$: Distancia entre x_i y x_j.
  - ρ_i: Distancia al vecino más cercano de x_i (define el umbral mínimo de distancia).
  - σ_i: Parámetro de suavizado adaptativo que ajusta la escala local.

Sensitivity: C2 Internal

Extracción de características: Manifold learning

UMAP (Uniform Manifold Approximation and Projection)

Importante que cada punto tiene su propia escala (mientras que en t-SNE nosotros fijamos la anchura/perplexity).

Esto consigue que todos los puntos tengan conexiones, ningún punto sea una isla. Incluso si un punto está muy lejos de los demás, UMAP "estira" su grafo local hasta que toca a sus vecinos.

Sensitivity: C2 Internal

Extracción de características: Manifold learning

UMAP (Uniform Manifold Approximation and Projection)

Unión lógica de todos los grafos locales para construir un grafo global de conexiones: Si el punto A "ve" un poquito al punto B, y el punto B "ve" un poquito al punto C... Hay conexión de A hasta C.

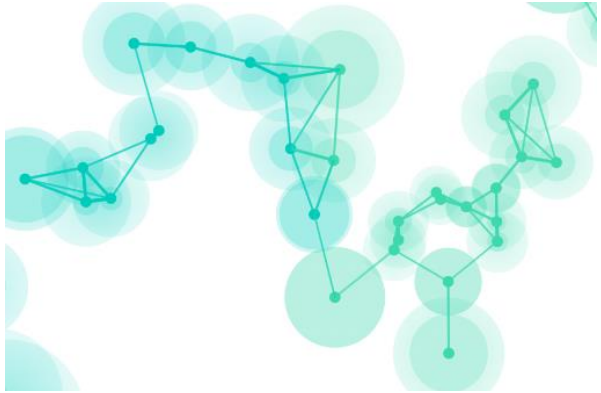

Sensitivity: C2 Internal

Extracción de características: Manifold learning

UMAP (Uniform Manifold Approximation and Projection)

Optimización del Grafo

Después de construir el grafo, UMAP optimiza una representación de menor dimensionalidad que conserva las relaciones locales y globales.

Objetivo de la Optimización:

- Minimizar la diferencia entre las relaciones en el grafo original y el grafo en el espacio reducido.

Usa una función de costo basada en entropía cruzada:

$$\mathcal{L} = \sum_{i,j} w_{ij} \log(q_{ij}) + (1 - w_{ij}) \log(1 - q_{ij})$$

- Donde:
  - q_{ij}: Afinidad en el espacio reducido:

$$q_{ij} = \frac{1}{1 + ||y_i - y_j||^2}$$

(y_i y y_j son las representaciones de x_i y x_j en el espacio reducido).

Sensitivity: C2 Internal

Extracción de características: Manifold learning

UMAP (Uniform Manifold Approximation and Projection)

Usar entropia cruzada en lugar de divergencia entre distribuciones fuerza mucho más que puntos alejados en el grafo original se alejen en el grafo del espacio reducido.

UMAP equilibra la conservación de la estructura local y global

Sensitivity: C2 Internal

Extracción de características: Manifold learning

UMAP (Uniform Manifold Approximation and Projection)

https://pair-code.github.io/understanding-umap/

Sensitivity: C2 Internal

Extracción de características: Manifold learning

Técnica	¿Lineal?	Enfoque	Estructura que preserva
PCA	Sí	Varianza	Global (Ejes ortogonales)
Isomap	No	Geométrico	Distancias geodésicas (curvas)
t-SNE	No	Probabilístico	Estructura Local (Clusters)
UMAP	No	Topológico	Local y Global (Equilibrado)

Sensitivity: C2 Internal

Extracción de características: Manifold learning

Principal curves

Las curvas principales se construyen mediante un proceso iterativo que considera las proyecciones de los puntos de datos sobre la curva y las proyecciones sobre las proyecciones.

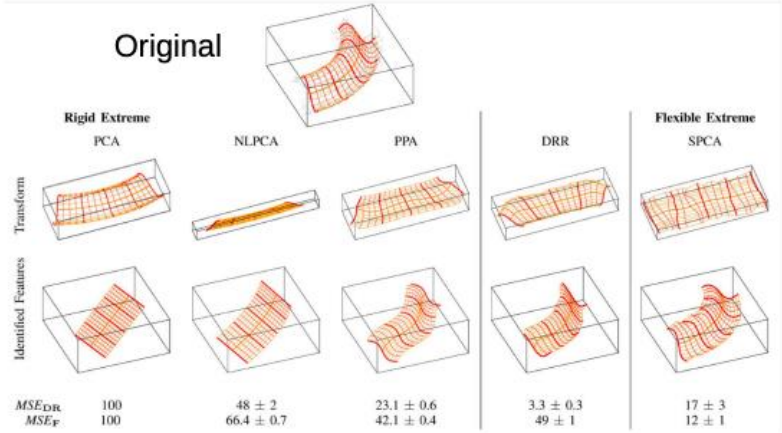

Sensitivity: C2 Internal

Extracción de características: Manifold learning

Autoencoder

Redes neuronales que comprimen y descomprimen los datos.

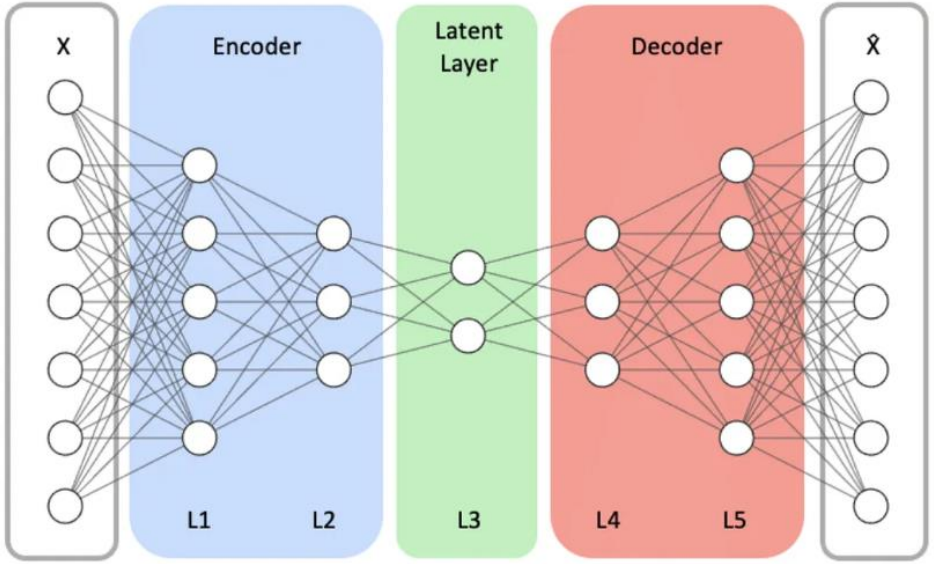

Sensitivity: C2 Internal